

第二届“良文杯” 统计建模与AI预测挑战赛 (金融大数据主题)

赛题说明会

主办单位：厦门大学经济学院、黄良文统计学科教育发展基金会

承办单位：厦门大学经济学院统计学与数据科学系、福建省统计科学重点实验室（厦门大学）

协办单位：上海艾托邦人工智能科技有限公司、广东艾托邦私募基金管理有限公司、
厦门大学经济学院金融系、厦门大学WISERCLUB社团

时 间：2026年3月27日



目录

CONTENTS


- 1. 赛事流程介绍
- 2. 赛题任务和理解
- 3. 数据说明和分析

1.1 赛事概况

- 赛题任务：利用订单簿和订单流数据预测股票价格走势
- 赛事亮点：
 - [量化实战] 稀缺的A股市场真实高频数据，探索量化实际挑战
 - [挑战升级] 更丰富的数据、更真实的评测场景，提供预处理特征
 - [丰厚奖励] 特等奖万元奖金，优胜团队可直通知名机构实习面试



[报名二维码]



[去年实习捷报]

1.2 赛事日历

比赛报名截止	3月29日 周日 晚 24:00	本周日晚 报名截止
初赛提交截止	5月11日 周一 (5月中上旬)	初赛开放: 持续6周
初赛成绩公布	5月18日 周一 (初赛提交后一周)	
决赛现场答辩 与颁奖典礼	5月30日 周六 (5月下旬或6月上旬)	

两轮赛制

- 初赛：本地训练模型，提交到线上平台评测模型代码
- 决赛：线下答辩，评委评分

“良文杯”统计建模与AI预测挑战赛（金融大数据主题）

竞赛规则

数据介绍

评测指南

公榜评测

私榜评测

评测任务

公榜成绩

请输入队名

创建评测任务

开放提交时间段

任务ID	队名	创建时间	任务状态	操作	日志
153	b	2025-04-09 23:02:33	评测中	删除	下载
152	b	2025-04-09 22:59:07	评测中	删除	下载
151	b	2025-04-09 21:27:20	评测完成	删除	下载

线上评测平台
(预计下周三开放)



1.3 初赛支持

没有金融基础？
无需担心！

- **赛题说明会**：赛题任务理解、背景知识介绍、赛题数据说明

- Sample数据格式：已发布

- 完整数据集：本周末

- 量化金融知识入门讲座

- **平台说明会**：平台使用说明和提交要求

- 开放初赛评测平台（预计下周三）

- 机器学习实操应用入门讲座

- **全程答疑支持**：有关赛事、有关数据、有关平台使用等等

- 每周线上集中答疑（预计周三，请关注QQ群通知）

- 参赛群内答疑

以赛代练
在挑战中学习成长！

数据、视频、文件发布在参赛QQ群公告网盘链接：



目录

CONTENTS

- 1. 赛事流程介绍
- 2. 赛题任务和理解
- 3. 数据说明和分析

2.1 赛题任务概要

- **预测目标：** 利用股票过往及当前数据预测未来中间价的移动方向
- **预测任务：** 5个不同未来时间的预测任务，取最好成绩参与排行
- **数据集：**
 - 5只匿名股票约半年的数据，频率为3秒一次
 - 数据已预先进行规范化和隐藏处理
 - 每个数据点包含5个预测标签的标注
 - 可自行划分训练集和验证集
- **预测方法：** 大数据分析、统计分析、机器学习、深度学习、强化学习等

[赛题优化]:

- 更丰富的数据字段——逐笔订单流的统计数据
- 提供基础的衍生特征——抛砖引玉，鼓励探索
- 更贴近真实交易场景（数据和评测）


2.2 赛题背景理解：订单簿

- 订单：股票市场的最小微观结构
- 订单委托：包含委托买入（或卖出）某支股票的量价信息 （不一定成交）
- 订单簿（Order Book），也称限价订单簿LOB
 - 所有订单委托按价格水平合并，在时序上做截面
 - 包含每个价格点（称作“一档”）委托买卖的股票数量
 - 交易所Level 1快照行情（每3秒切片采样）包含5档最优档位买卖量价

订单委托

交易意愿的体现

当日委托		当日成交	历史委托
股票/时间	委价/均价	委量/成交	
上证综合	1.050	300	
13:58:59	0.000	0	



某只股票截图时刻的最新五档订单簿和股价走势图

2.2 赛题背景理解：股票成交

订单成交

当日委托	当日成交	历史委托	历史成交
时间	名称/代码	价格/数量	方向/金额
2025-04-09 09:36:12	上证综合 510980	1.047 200	证券买入 209.400

■ 最优档位：距离成交最近


- 买一价 (bid1) 为当前最高买入报价，示例中bid1为37.58
- 卖一价 (ask1) 为当前最低卖出报价，示例中ask1为37.59

bid #	price	ask #
	37.63	71
	37.62	124
	37.61	175
	37.60	250
	37.59	578
买一/bid1	173	37.58
	155	37.57
	272	37.56
	195	37.55
买五/bid5	171	37.54

股票A五档订单簿快照结构

卖五/ask5
↑
卖一/ask1

以价格37.59元买入
100手股票A



买入委托

主动单 vs 被动单

bid #	price	ask #
	37.63	71
	37.62	124
	37.61	175
	37.60	250
	37.59	478
173	37.58	
155	37.57	
272	37.56	
195	37.55	
171	37.54	

股票成交后的订单簿更新

成交!
↑

■ 股票成交：想立刻买入100手该股票？下单立刻成交

- 匹配卖一价
- 或高于卖一价

2.2 赛题背景理解：六类订单——买卖意愿

■ 买单: buy/bid 缩写b

下单

- 限价单: limit 缩写l
- 市价单: market 缩写m
- 撤单: cancel 缩写c

■ 卖单: sell/ask 缩写a

下单

- 限价单: limit 缩写l
- 市价单: market 缩写m
- 撤单: cancel 缩写c

■ 如果涨?

- 限价买单和市价买单增加
- 买撤单减少
- 限价卖单和市价卖单减少

bid #	price	ask #
	37.63	71
	37.62	124
	37.61	175
	37.60	250
	37.59	578
173	37.58	
155	37.57	
272	37.56	
195	37.55	
171	37.54	

买一/bid1
↓
买五/bid5

卖五/ask5
↑
卖一/ask1

股票A五档订单簿快照结构

市价单的成交意愿比限价单更强

研究区分六类订单

[关注订单成交特性 立刻成交 vs 等等?]:

主动买单记为mb, 主动卖单记为ma

被动买单记为lb, 被动卖单记为la

买单撤单记为cb, 卖单撤单记为ca

2.2 赛题背景理解：行情快照

■ 行情快照（Snapshot）：

- 对交易所**逐笔订单流**进行**切片采样**形成的连续tick序列数据点
- 1个数据点也称为1个tick的snapshot，数据频率一般是3秒

	上交所		深交所	
	Level 1	Level 2	Level 1	Level 2
盘口发布频率	3秒1次	3秒1次	3秒1次	3秒1次
委托档位信息	5档	10档	5档	10档
基本行情信息	最新价，当日累计成交量，当日累计成交额，当日最高成交价，当日最低成交价，昨收盘价等			
增强行情信息		最优档位的前50笔订单的委托量，实时逐笔成交信息（毫秒级），委托买/卖总量，买/卖均价等		最优档位的前50笔订单的委托量，实时逐笔委托，实时逐笔成交信息（毫秒级）等

- Level 1 -> Level2
- 五档 -> 十档
- [新增]委买/委卖总量、均价
- [新增]逐笔数据的统计特征


2.3 赛题任务理解：中间价

■ 预测目标：利用股票过往及当前数据预测未来**中间价**的移动方向

■ 如何定义中间价？

■ 买一价和卖一价的均值 $midprice = \begin{cases} \frac{ask1+bid1}{2}, & \text{if } ask1 \neq 0 \text{ and } bid1 \neq 0 \\ ask1, & \text{if } bid1 = 0 \text{ (例如跌停)} \\ bid1, & \text{if } ask1 = 0 \text{ (例如涨停)} \end{cases}$

多种定义方式



中间价和买一/卖一价对比图

2.3 赛题任务理解：5个未来预测任务

- **预测目标：**利用股票过往及当前数据预测**未来**中间价的移动方向
 - **预测时间跨度：**5、10、20、40、60个tick，5个预测任务
 - 在t时刻，
 - 允许利用过去不超过100tick（包含当前tick）的数据，
 - 分别预测t+5tick，t+10tick，t+20tick，t+40tick，t+60tick以后：
 - 最新中间价相较t时刻的中间价：下跌/不变/上涨
- **取5个预测任务中最高得分参与排行**

2.3 赛题任务理解：移动方向

■ **预测目标：**利用股票过往及当前数据预测未来中间价的**移动方向**

■ **如何定义midprice的移动方向？**

■ 上涨，下跌和（在一定范围内）稳定

■ $x = \text{待预测时刻的midprice} - \text{当前时刻的midprice}$

$$\phi(x) = \begin{cases} 0 & x < -\alpha \\ 1 & -\alpha \leq x \leq \alpha \\ 2 & \alpha < x \end{cases}$$

■ 0表示下跌，1表示不变，2表示上涨

■ 对于预测窗口为5tick、10tick， α 取0.05%

■ 对于预测窗口20tick、40tick、60tick， α 取0.1%

如果预测未来涨？
——当前买入，未来卖出



目录

CONTENTS

- 1. 赛事流程介绍
- 2. 赛题任务和理解
- 3. 数据说明和分析

3.1 数据位置

- 数据集发布在参赛群公告网盘链接：
- 所有行情文件以
 - snapshot_sym<xx>_date<yy>_am/pm.parquet
命名，代表第xx只证券标的在第yy天的上午/
下午的行情数据
- Parquet文件：
 - 压缩存储效率高、数据类型准确

snapshot_sym0_date0_am.parquet	PARQUET 文件	271 KB
snapshot_sym0_date0_pm.parquet	PARQUET 文件	233 KB
snapshot_sym0_date1_am.parquet	PARQUET 文件	272 KB
snapshot_sym0_date1_pm.parquet	PARQUET 文件	209 KB
snapshot_sym0_date2_am.parquet	PARQUET 文件	247 KB
snapshot_sym0_date2_pm.parquet	PARQUET 文件	243 KB
snapshot_sym0_date3_am.parquet	PARQUET 文件	383 KB
snapshot_sym0_date3_pm.parquet	PARQUET 文件	290 KB
snapshot_sym0_date4_am.parquet	PARQUET 文件	273 KB
snapshot_sym0_date4_pm.parquet	PARQUET 文件	221 KB
snapshot_sym0_date5_am.parquet	PARQUET 文件	221 KB
snapshot_sym0_date5_pm.parquet	PARQUET 文件	184 KB

3.2 数据说明

- 数据概览：
 - 5只标的股票
 - 120个交易日，约半年
 - 数据频率为3秒一次
 - 剔除开盘后&收盘前10分钟数据
 - 9:40-11:20, 13:10-14:50
 - 一个连续时段约2000个

	date	sym	time	open	high	low	close	volume_delta	amount_delta	bid1	...	asize_rate7	asize_rate8	...
0	0	0	09:40:00	0.005398	0.010121	-0.009447	-0.004723	0.000270	107675.0	-0.005398	...	0.000000	0.000000	...
1	0	0	09:40:03	0.005398	0.010121	-0.009447	-0.004723	0.000141	56037.0	-0.005398	...	0.000000	0.000000	...
2	0	0	09:40:06	0.005398	0.010121	-0.009447	-0.004049	0.002226	886598.0	-0.004049	...	-0.000226	-0.001030	...
3	0	0	09:40:09	0.005398	0.010121	-0.009447	-0.004049	0.000385	153530.0	-0.004049	...	0.000000	0.000000	...
4	0	0	09:40:12	0.005398	0.010121	-0.009447	-0.004049	0.000833	332269.0	-0.004049	...	-0.000304	0.000311	...
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
1996	0	0	11:19:48	0.005398	0.012821	-0.009447	0.012146	0.000081	33000.0	0.012146	...	0.000000	0.000000	...
1997	0	0	11:19:51	0.005398	0.012821	-0.009447	0.012146	0.000044	18000.0	0.012146	...	0.000000	-0.000015	...
1998	0	0	11:19:54	0.005398	0.012821	-0.009447	0.012146	0.000263	106560.0	0.010796	...	0.000696	-0.000107	...
1999	0	0	11:19:57	0.005398	0.012821	-0.009447	0.012146	0.000019	7500.0	0.010796	...	0.000000	0.000000	...
2000	0	0	11:20:00	0.005398	0.012821	-0.009447	0.012146	0.000056	22500.0	0.010796	...	0.000074	0.000000	...

2001 rows × 163 columns

3.2 数据说明

■ 信息戳

- 日期、时间、股票代码

■ 成交量价数据

- amount_delta、volume_delta
- close/open/low/high

■ 订单簿十档量价数据

- ask/bid/asksize/bsize

■ 订单流统计特征

- 订单到达强度、加速度

■ 基于订单簿十档量价的衍生特征

■ 中间价和多周期预测标签

154特征

匿名后的真实市场行情数据
真实体验股票量化交易挑战

68特征

提供预处理特征
更快上手！更多探索！

86特征

多周期预测更灵活

3.3 字段说明-1

字段	含义	说明
date	日期	去掉实际日期，但保留序号，取值范围0~119，保留跨标的的可比性
time	时间戳	保留实际时间戳，3s一档行情
sym	股票标的	仅序号，5只股票分别为0~4
close	最新成交价	无量纲，以相对昨收的涨跌幅表示，-1~1，即跌100%到涨100%（实际取值范围更小），下同
open	开盘价	
high	当前最高价	
low	当前最低价	
amount_delta	成交金额变化	从上个tick到当前tick发生的成交金额，单位：元
volume_delta	成交量变化	从上个tick到当前tick发生的成交量，无量纲，以换手率%表示
bid1 ~ bid10	买一价-买十价	无量纲，以涨跌幅表示
ask1 ~ ask10	卖一价-卖十价	无量纲，以涨跌幅表示
bsize1 ~ bsize10	买一量-买十量	无量纲，以换手率%表示
asize1 ~ asize10	卖一量-卖十量	无量纲，以换手率%表示
midprice	中间价	无量纲，以涨跌幅表示
label_5, label_10, label_20, label_40, label_60	5tick, 10tick, 20tick, 40tick, 60tick后价格移 动方向	当前tick中间价相对于5tick, 10tick, 20tick, 40tick, 60tick之前的移动方向，0为下跌，1为不变，2为上涨

3.3 字段说明-2 新增数据

字段	含义	说明
avgbid	委买均价（千档）	无量纲，以涨跌幅表示
avgask	委卖均价（千档）	无量纲，以涨跌幅表示
totalbsize	委买总量（千档）	无量纲，以换手率%表示
totalasize	委卖总量（千档）	无量纲，以换手率%表示
lb_intst	限价买单到达强度	从上个tick到当前tick，限价买单平均到达强度。订单量已转化为换手率%，下同
la_intst	限价卖单到达强度	
mb_intst	市价买单到达强度	
ma_intst	市价卖单到达强度	
cb_intst	买单撤单强度	
ca_intst	卖单撤单强度	
lb_ind, la_ind, mb_ind, ma_ind, cb_ind, ca_ind	六类订单强度指标	六类订单过去1 tick的平均强度是否大于过去60 tick的平均强度。1为True，0为False
lb_acc, la_acc, mb_acc, ma_acc, cb_acc, ca_acc	六类订单强度平均变化率	从上个tick到当前tick，六类订单到达强度平均变化率（可以理解为到达的加速度）。订单量已转化为换手率%

3.3 字段说明-3 订单簿衍生特征

字段	含义	说明
midprice1 ~ midprice10	十档中间价	订单簿衍生特征，详见论文，下同
spread1 ~ spread10	十档买卖价差	
bid_diff1 ~ bid_diff10	档位价差	
ask_diff1 ~ ask_diff10	档位价差	
bid_mean	十档均价	
ask_mean	十档均价	
bsize_mean	十档均量	
asize_mean	十档均量	
cumuspread	十档累计买卖价差	
imbalance	十档累计买卖量差	
bid_rate1 ~ bid_rate10	十档价格平均变化率	
ask_rate1 ~ ask_rate10	十档价格平均变化率	
bsize_rate1 ~ bsize_rate10	十档委量平均变化率	
asize_rate1 ~ asize_rate10	十档委量平均变化率	

衍生特征详见论文：Modelling high-frequency limit order book dynamics with support vector machines

3.3 字段列表

```
[
# 基本信息
'date', 'sym', 'time',
# 成交快照
'open', 'high', 'low', 'close', 'volume_delta', 'amount_delta',
# 订单簿快照
'bid1', 'bsize1', 'bid2', 'bsize2', 'bid3', 'bsize3', 'bid4', 'bsize4', 'bid5', 'bsize5',
'bid6', 'bsize6', 'bid7', 'bsize7', 'bid8', 'bsize8', 'bid9', 'bsize9', 'bid10', 'bsize10',
'ask1', 'asize1', 'ask2', 'asize2', 'ask3', 'asize3', 'ask4', 'asize4', 'ask5', 'asize5',
'ask6', 'asize6', 'ask7', 'asize7', 'ask8', 'asize8', 'ask9', 'asize9', 'ask10', 'asize10',
'avgbid', 'avgask', 'totalbsize', 'totalasize',
# 订单到达逐笔统计特征
'lb_intst', 'la_intst', 'mb_intst', 'ma_intst', 'cb_intst', 'ca_intst',
'lb_ind', 'la_ind', 'mb_ind', 'ma_ind', 'cb_ind', 'ca_ind',
'lb_acc', 'la_acc', 'mb_acc', 'ma_acc', 'cb_acc', 'ca_acc',
# 订单簿衍生特征
'midprice1', 'midprice2', 'midprice3', 'midprice4', 'midprice5', 'midprice6', 'midprice7', 'midprice8', 'midprice9', 'midprice10',
'spread1', 'spread2', 'spread3', 'spread4', 'spread5', 'spread6', 'spread7', 'spread8', 'spread9', 'spread10',
'bid_diff1', 'bid_diff2', 'bid_diff3', 'bid_diff4', 'bid_diff5', 'bid_diff6', 'bid_diff7', 'bid_diff8', 'bid_diff9', 'bid_diff10',
'ask_diff1', 'ask_diff2', 'ask_diff3', 'ask_diff4', 'ask_diff5', 'ask_diff6', 'ask_diff7', 'ask_diff8', 'ask_diff9', 'ask_diff10',
'bid_mean', 'ask_mean', 'bsize_mean', 'asize_mean',
'cumsread', 'imbalance',
'bid_rate1', 'bid_rate2', 'bid_rate3', 'bid_rate4', 'bid_rate5', 'bid_rate6', 'bid_rate7', 'bid_rate8', 'bid_rate9', 'bid_rate10',
'ask_rate1', 'ask_rate2', 'ask_rate3', 'ask_rate4', 'ask_rate5', 'ask_rate6', 'ask_rate7', 'ask_rate8', 'ask_rate9', 'ask_rate10',
'bsize_rate1', 'bsize_rate2', 'bsize_rate3', 'bsize_rate4', 'bsize_rate5', 'bsize_rate6', 'bsize_rate7', 'bsize_rate8', 'bsize_rate9', 'bsize_rate10',
'asize_rate1', 'asize_rate2', 'asize_rate3', 'asize_rate4', 'asize_rate5', 'asize_rate6', 'asize_rate7', 'asize_rate8', 'asize_rate9', 'asize_rate10',
# 中间价
'midprice',
# 预测标签
'label_5', 'label_10', 'label_20', 'label_40', 'label_60'
]
```



3.4 探索数据

Step1：检查数据

- 是否有缺失值？
可能挺多的？缺20%以上可以直接去掉
- 是否有异常值？
变化幅度，查看分布
- 是否有重复值？
价格可能不变，amount不太可能
- 样本是否均衡？
涨、跌、不变的分布是否均衡
- 是否需要抽样？
- 变量是否需要转换？
- 是否需要增加新的特征？

3.4 探索数据

Step1: 检查数据

读入单个文件并观察 ¶

```
file_dir = "./2026liangwen/2026train_set"

sym = 0
date = 0
file_name = f"snapshot_sym{sym}_date{date}_am.parquet"

df = pd.read_parquet(os.path.join(file_dir,file_name))
df
```

	date	sym	time	open	high	low	close	volume_delta	amount_delta	bid1	...	asize_rate7	asize_rate8	a
0	0	0	09:40:00	0.005398	0.010121	-0.009447	-0.004723	0.000270	107675.0	-0.005398	...	0.000000	0.000000	
1	0	0	09:40:03	0.005398	0.010121	-0.009447	-0.004723	0.000141	56037.0	-0.005398	...	0.000000	0.000000	
2	0	0	09:40:06	0.005398	0.010121	-0.009447	-0.004049	0.002226	886598.0	-0.004049	...	-0.000226	-0.001030	
3	0	0	09:40:09	0.005398	0.010121	-0.009447	-0.004049	0.000385	153530.0	-0.004049	...	0.000000	0.000000	
4	0	0	09:40:12	0.005398	0.010121	-0.009447	-0.004049	0.000833	332269.0	-0.004049	...	-0.000304	0.000311	
...	...	...	...	...	...	...	...	...	...	...	...	...	...	
1996	0	0	11:19:48	0.005398	0.012821	-0.009447	0.012146	0.000081	33000.0	0.012146	...	0.000000	0.000000	
1997	0	0	11:19:51	0.005398	0.012821	-0.009447	0.012146	0.000044	18000.0	0.012146	...	0.000000	-0.000015	
1998	0	0	11:19:54	0.005398	0.012821	-0.009447	0.012146	0.000263	106560.0	0.010796	...	0.000696	-0.000107	
1999	0	0	11:19:57	0.005398	0.012821	-0.009447	0.012146	0.000019	7500.0	0.010796	...	0.000000	0.000000	
2000	0	0	11:20:00	0.005398	0.012821	-0.009447	0.012146	0.000056	22500.0	0.010796	...	0.000074	0.000000	

2001 rows × 163 columns



3.4 探索数据

Step1: 检查数据

■ 确定是否有异常值/缺失值

- 我们在真实生活中遇到的都是有噪音/有残缺的“脏”数据
- 比赛数据集尽可能的去除了异常值，但是仍然可能在处理过程中出现
- 如果有，怎么办？
 - 用0填充？还是其他填充方式？考虑可行性
 - 舍弃字段/条目？
 - 可能有时候异常值也代表着某些信息？

检查异常值/缺失值

```
# 确定有无na值，若有要进行处理（是否一定能用0填充）  
df.isnull().values.any()
```

False

```
# 确定有无inf值  
cols = df.columns  
for col in cols:  
    # 如果不是object  
    if not(df[col].dtypes == 'object'):  
        # 判断是否有inf值，有则打印列名  
        if not (np.all(np.isfinite(df[col].values))):  
            print(col)
```

3.4 探索数据

Step2: 观察并分析数据

- 怎么观察数据分布？
 - 查看数据属性: `Dataframe.describe()`
 - 绘图观察: `Dataframe.plot()`
 -

3.4 探索数据

Step2: 观察并分析数据

■ 要注意观察哪些信息？

- 数据范围
- 数据分布
-

■ 计算精度考虑

- 数量级差异

df.describe()

	open	high	low	close	volume_delta	amount_delta	bid1	bsize1
count	2.001000e+03	2001.000000	2.001000e+03	2001.000000	2001.000000	2.001000e+03	2001.000000	2.001000e+03
mean	5.398111e-03	0.011142	-9.446694e-03	0.003566	0.000240	9.646880e+04	0.003200	7.018719e-04
std	2.802279e-16	0.000827	1.353423e-16	0.003500	0.000610	2.451865e+05	0.003469	9.176487e-04
min	5.398111e-03	0.010121	-9.446694e-03	-0.004723	0.000000	0.000000e+00	-0.005398	4.444444e-07
25%	5.398111e-03	0.010796	-9.446694e-03	0.000675	0.000011	4.479000e+03	0.000000	1.814815e-04
50%	5.398111e-03	0.010796	-9.446694e-03	0.002699	0.000070	2.826500e+04	0.002024	4.592593e-04
75%	5.398111e-03	0.010796	-9.446694e-03	0.006748	0.000226	9.046300e+04	0.006073	8.645926e-04
max	5.398111e-03	0.012821	-9.446694e-03	0.012146	0.008863	3.567967e+06	0.012146	9.737037e-03

8 rows × 160 columns

```
1 ## 当数量级不一致时，很有可能影响后续计算结果
2 print(1e-10 + 1.0 == 1.0)
3 print(1e-20 + 1.0 == 1.0)
4 ## 譬如上图的amount_delta
```

False
True

按换手率%、涨跌幅处理


3.4 探索数据

Step2: 观察并分析数据

- 要注意观察哪些信息?
 - 有没有不合理的数据?
 - 数据有没有呈现什么规律?


```
df[['bid1','ask1','midprice']].plot(figsize = (16,4))
```

<Axes: >



```
df[['bid2','bid3','ask2','ask3']].plot(figsize = (16,4))
```

<Axes: >





3.4 探索数据

Step2: 观察并分析数据

- 要注意观察哪些信息?
 - 有没有不合理的数据?
 - 数据有没有呈现什么规律?
- 是否需要抽样进一步观察?
 - 涨跌才有机会
 - 全体 -> 涨跌?

仅作参考

更多特征有待探索...



3.4 探索数据

Step3: 构造更多特征/因子

网上查找、研报、论文、AI...

■ 做一些简单处理

标准化处理有没有可能带来新的问题

■ 已做了量价标准化处理：价格相对昨收的涨跌、订单量转化为换手率%

■ 为简单模型提供更多特征, 复杂的模型可能自己就能抽取出来这些

特征维数太多怎么办?

价格+1 (从涨跌幅还原到对前收盘价的比例)

```
new_df['bid1'] = new_df['n_bid1'] + 1
new_df['bid2'] = new_df['n_bid2'] + 1
new_df['bid3'] = new_df['n_bid3'] + 1
new_df['bid4'] = new_df['n_bid4'] + 1
new_df['bid5'] = new_df['n_bid5'] + 1
new_df['ask1'] = new_df['n_ask1'] + 1
new_df['ask2'] = new_df['n_ask2'] + 1
new_df['ask3'] = new_df['n_ask3'] + 1
new_df['ask4'] = new_df['n_ask4'] + 1
new_df['ask5'] = new_df['n_ask5'] + 1
```

对量取对数

```
new_df['bsize1'] = new_df['n_bsize1'].map(np.log)
new_df['bsize2'] = new_df['n_bsize2'].map(np.log)
new_df['bsize3'] = new_df['n_bsize3'].map(np.log)
new_df['bsize4'] = new_df['n_bsize4'].map(np.log)
new_df['bsize5'] = new_df['n_bsize5'].map(np.log)
new_df['asize1'] = new_df['n_asize1'].map(np.log)
new_df['asize2'] = new_df['n_asize2'].map(np.log)
new_df['asize3'] = new_df['n_asize3'].map(np.log)
new_df['asize4'] = new_df['n_asize4'].map(np.log)
new_df['asize5'] = new_df['n_asize5'].map(np.log)
new_df['amount'] = new_df['amount_delta'].map(np.log1p)
```

量价组合

```
new_df['spread1'] = new_df['ask1'] - new_df['bid1']
new_df['spread2'] = new_df['ask2'] - new_df['bid2']
new_df['spread3'] = new_df['ask3'] - new_df['bid3']
new_df['mid_price1'] = new_df['ask1'] + new_df['bid1']
new_df['mid_price2'] = new_df['ask2'] + new_df['bid2']
new_df['mid_price3'] = new_df['ask3'] + new_df['bid3']
new_df['weighted_ab1'] = (new_df['ask1'] * new_df['n_bsize1'] + new_df['bid1'] * new_df['n_asize1']) / (new_df['ask1'] + new_df['bid1'])
new_df['weighted_ab2'] = (new_df['ask2'] * new_df['n_bsize2'] + new_df['bid2'] * new_df['n_asize2']) / (new_df['ask2'] + new_df['bid2'])
new_df['weighted_ab3'] = (new_df['ask3'] * new_df['n_bsize3'] + new_df['bid3'] * new_df['n_asize3']) / (new_df['ask3'] + new_df['bid3'])
```

```
new_df['relative_spread1'] = new_df['spread1'] / new_df['mid_price1']
new_df['relative_spread2'] = new_df['spread2'] / new_df['mid_price2']
new_df['relative_spread3'] = new_df['spread3'] / new_df['mid_price3']
```

均线特征

```
new_df['ask1_ma5'] = new_df['ask1'].rolling(window=5, min_periods=1).mean()
new_df['ask1_ma10'] = new_df['ask1'].rolling(window=10, min_periods=1).mean()
new_df['ask1_ma20'] = new_df['ask1'].rolling(window=20, min_periods=1).mean()
new_df['ask1_ma40'] = new_df['ask1'].rolling(window=40, min_periods=1).mean()
new_df['ask1_ma60'] = new_df['ask1'].rolling(window=60, min_periods=1).mean()
new_df['bid1_ma5'] = new_df['bid1'].rolling(window=5, min_periods=1).mean()
new_df['bid1_ma10'] = new_df['bid1'].rolling(window=10, min_periods=1).mean()
new_df['bid1_ma20'] = new_df['bid1'].rolling(window=20, min_periods=1).mean()
new_df['bid1_ma40'] = new_df['bid1'].rolling(window=40, min_periods=1).mean()
new_df['bid1_ma60'] = new_df['bid1'].rolling(window=60, min_periods=1).mean()
```

THANKS!