

因子工程六大家族详解

良文杯 2026 LOB 中间价方向预测—SchemeP 共 370 维因子拆解

史景喆（清华大学）

团队：超级回天什么时候上映 | 公榜 #1 (+35.64) | 私榜 #1

2026 年 5 月

1. 摘要

本报告对良文杯 2026 决赛冠军方案 SchemeP 的特征体系做技术性拆解。SchemeP 在 $T = 100$ tick 因果窗口上构造 370 维特征向量，其中 154 维原始字段 + 216 维派生因子（T3 / Stage 1 / Stage 2 / Stage 3 / Stage 5 五个特征阶段）。

依据语义将所有 370 个因子归入六大家族：F1 LOB 派生（105 维）、F2 多尺度 OFI（50 维）、F3 订单流强度（45 维）、F4 微结构波动（29 维）、F5 窗口统计（67 维）、F6 不对称性（74 维）。

LightGBM ($h = 60$, 50-seed M7 重训第 1 个 seed) 的特征重要性显示：F1 占 gain 40.4% (top: asize1, totalasize, bsize1)、F3 占 gain 35.1% (top: ma_intst, mb_intst)，两者合计 75.5%，构成预测主力。F5 / F6 / F2 各贡献 5–7% gain，但提供 OOD 稳健性与决策边界精炼。

家族内最大冗余出现在 F2（块内平均 $|r| = 0.33$ ），即多尺度 OFI 高度共线；家族间最大跨家族相关出现在 $F2 \leftrightarrow F6$ （GOFI 与 MLOFI 同源， $|r| \approx 0.18$ ）。这一结构合理性也解释了为何窗口 z-score (window-z) 是决胜 OOD 的核心预处理：它把 F1/F3 的绝对水平转换为 100-tick 内的相对位置，跨股票/跨日基差被显著压缩，比赛 OOD 期 PnL 增益 +42.29 ($-6.65 \rightarrow +35.64$)。

2. 数据基底与构造管线

原始字段（154 维）：来自盘口 snapshot parquet，每 tick 包含

- OHLCV：open, high, low, close, volume_delta, amount_delta（6 维）；
- 10 档买卖盘价 bidk / askk（20 维）与挂单量 bsizek / asizek（20 维）， $k \in \{1..10\}$ ；
- 行情衍生量 avgbid, avgask, totalbsize, totalasize（4 维）、bid_mean, ask_mean, bsize_mean, asize_mean（4 维）；
- 主办方提供的中位价与价差 midpricek, spreadk（20 维）、cumsread, imbalance（2 维）、价差 bid_diffk, ask_diffk（20 维）；
- 六类订单事件强度——挂单 lb/la_intst、成交 mb/ma_intst、撤单 cb/ca_intst 及其 _ind / _acc 变体（18 维）；
- 主办方滑动平均变化率 bid_ratek / ask_ratek / bsize_ratek / asize_ratek（40 维）。

派生因子（216 维）：在长度 $T = 100$ 的滑动窗口上一次性向量化 (sliding_window_view) 后批量计算，按 stage 顺序拼接：

$$\underbrace{X_{\text{raw}}}_{154} \oplus \underbrace{X_{T3}}_{69} \oplus \underbrace{X_{S1}}_{54} \oplus \underbrace{X_{S2}}_{59} \oplus \underbrace{X_{S3}}_{14} \oplus \underbrace{X_{S5}}_{20} = 370.$$

其中 T3 含 MLOFI / WMP / RV / EWMA-intst, Stage 1 含 dual-z / signed-RV / Kyle / EWMA-OFI, Stage 2 含 qrank / skew / GOFI / Kyle- λ / vol-burst, Stage 3 含 EWMA 残差 / RV ratio / jump-share / cancel-imb / Roll 效价比, Stage 5 含 adaptive-momentum / OFI-toxicity / signed-bipower / spread-regime / trade-persistence / liq-asym。

标签：5 个 horizon $h \in \{5, 10, 20, 40, 60\}$ 的 3 类方向（涨 / 平 / 跌）。比赛主力使用 $h = 60$ 。

硬约束（CRITICAL_CONSTRAINTS）：评测时 date=0、sym 0–4 可含训练外股票、测试点顺序被打乱。因此所有 370 个因子都满足：(i) 不显式使用 date / sym；(ii) 每条样本独立可算，不依赖跨样本状态；(iii) sym-agnostic，不嵌入 sym embedding 或 sym-conditional 归一化。

两类全局预处理：

- amount_delta 在 raw last-tick 处做 sign-preserving log1p: $x \mapsto \text{sign}(x) \cdot \log(1 + |x|)$ ，控制重尾；
- 全特征再做一次 log1p (cache 命名前缀 cache_log1p)；
- 训练阶段 drop11: 丢弃 11 个对 OOD 有噪声漂移的因子 (详见 g6)。

3. 家族总览

家族	因子数	占总数 (%)	LGB gain 占比 (%)
F1 LOB 派生	105	28.4	40.4
F2 多尺度 OFI	50	13.5	5.5
F3 订单流强度	45	12.2	35.1
F4 微结构波动	29	7.8	7.5
F5 窗口统计	67	18.1	5.2
F6 不对称性	74	20.0	6.3
合计	370	100	100

Table 1: 六大家族因子数与 LightGBM 特征重要性 (gain, h=60 M7 模型 seed=1)。F1 + F3 = 75.5%，是预测主力；其余四家族每族 5-8%，承担 OOD 稳健性与决策精炼。




Figure 1: 各家族因子数与 gain 占比对比: F1 因子数占比 28.4% 但 gain 占比 40.4% (单因子贡献最强); F5 占比 18.1%、gain 仅 5.2% (每个 z-score 因子单看不重要, 胜在协同与 OOD 稳健)。

4. 六大因子家族

4.1 家族 F1: LOB 派生 (105 维)

动机。盘口 snapshot 自身的价格水平、挂单深度与中位价是任何方向预测的最基本输入。本家族包含原始 OHLC、10 档买卖盘价/量、价差、中位价、加权微价格 WMP，以及订单簿层间结构 bid_diff / ask_diff (同侧相邻档位间价格差)。它们刻画"当下盘口长什么样"，是 F2-F6 衍生因子的基底。

因子清单。

因子 (命名)	维度	含义与公式
open,high,low,close	4	当前 tick 之前 5 ticks 聚合的 K 线四要素
bid _k , ask _k	20	10 档买卖盘价 $k \in \{1..10\}$
bsize _k , asize _k	20	10 档买卖盘挂单量
avgbid, avgask	2	当 tick 内成交均价 (买/卖侧)
totalbsize, totalasize	2	10 档买卖侧累计挂单量
bid_mean, ask_mean	2	10 档买/卖侧价格均值
bsize_mean, asize_mean	2	10 档买/卖侧挂单量均值
midprice _k	10	$(bid_k + ask_k)/2$, 10 档分别
spread _k	10	$ask_k - bid_k$, 10 档分别
cumspread	1	10 档价差累计和
imbalance	1	$(totalbsize - totalasize)/(totalbsize + totalasize)$
bid_diff _k , ask_diff _k	20	同侧相邻档位间价差, 刻画 LOB 形态
wmp_lv1 _k	10	加权中价 $WMP_k = \frac{ask_k \cdot bsize_k + bid_k \cdot asize_k}{bsize_k + asize_k}$ (denominator 为 0 时回退到普通 mid)
wmp_balance_12	1	$WMP_1 - WMP_2$, 跨档微价格梯度

Table 2: F1 LOB 派生 105 维因子。

核心代码——WMP (加权微价格):

```
for k in T3_LOB_LEVELS: # 1..10
    b = X3d[:, :, col_idx[f"bid{k}"]]
    a = X3d[:, :, col_idx[f"ask{k}"]]
    bs = X3d[:, :, col_idx[f"bsize{k}"]]
    asz = X3d[:, :, col_idx[f"asize{k}"]]
    denom = bs + asz
    wmp_normal = (a * bs + b * asz) / np.where(denom == 0, 1.0, denom)
    wmp_fallback = (a + b) / 2.0
    wmp = np.where(denom == 0, wmp_fallback, wmp_normal)
    out[:, col] = wmp[:, -1]; col += 1
out[:, col] = wmp_per_level[0][:, -1] - wmp_per_level[1][:, -1] # wmp_balance_12
```

注意 WMP 的符号约定: 分子用 ask*bsize + bid*asize ("短缺侧权重"), 符合 Stoikov 微价格直觉, 挂单越少的一侧把 WMP 拉得越接近其报价。




Figure 2: F1 家族内 Pearson 相关性 (采样 10 万行 train)。家族内平均 $|r| = 0.154$ 。10 档同名因子 (如 bid1..bid10) 形成明显对角块, midprice k 与 wmp_lv k 高度相关 (同向价值)。尽管冗余存在, 多档信息对 LightGBM 树模型仍有边际价值。

4.2 家族 F2: 多尺度 OFI (50 维)

动机。 订单流不平衡 (Order-Flow Imbalance, OFI) 是预测短期方向的最强单一信号家族 (Cont 2014)。SchemeP 在多窗口长度 ($W \in \{5, 20, 60\}$ for MLOFI; $W \in \{50, 100\}$ for Kyle/toxicity) 与多 EWMA 半衰期 ($\alpha \in \{0.05, 0.1, 0.3, 0.5\}$) 的乘积空间内构造 50 维 OFI 表达, 对不同响应速度的市场状态都有覆盖。

因子清单。

因子 (命名)	维度	含义
mlofi_WW_lv k	30	k 档 OFI 在过去 W tick 的求和, $W \in \{5, 20, 60\}$, $k \in \{1..10\}$
ewma_ofi_a α _lv k	12	MLOFI $_{W=20,k}$ 上的 EWMA(α), $\alpha \in \{0.05, 0.1, 0.3, 0.5\}$, $k \in \{1, 5, 10\}$
kyle_inv_WW	2	反 Kyle 价格冲击: $\text{amount} / \sqrt[3]{ \text{amount} \cdot \sigma_W}$, $W \in \{50, 100\}$
kyle_lam_WW	2	Kyle λ : $\text{cov}(\Delta P, \text{signed_dvol}) / \text{var}(\text{signed_dvol})$
ofi_tox_lv k _WW	4	OFI 毒性: $\text{corr}(\text{OFI}_k, \Delta \text{mid})$ over W , $(k, W) \in \{(1, 20), (1, 50), (5, 20), (5, 50)\}$

Table 3: F2 多尺度 OFI 50 维因子。

核心公式——MLOFI (Cont 2014 multi-level OFI): 对每一档 k , 单 tick 增量

$$e_t^{(k)} = \mathbf{1}_{b_t^{(k)} \geq b_{t-1}^{(k)}} \text{bs}_t^{(k)} - \mathbf{1}_{b_t^{(k)} \leq b_{t-1}^{(k)}} \text{bs}_{t-1}^{(k)} - \mathbf{1}_{a_t^{(k)} \leq a_{t-1}^{(k)}} \text{as}_t^{(k)} + \mathbf{1}_{a_t^{(k)} \geq a_{t-1}^{(k)}} \text{as}_{t-1}^{(k)}.$$

再做窗口求和 $MLOFI_{t,W}^{(k)} = \sum_{s=t-W+1}^t e_s^{(k)}$ 。 b 上行（或持平）时贡献 $+bs$ ； b 下行时减去前一档 bs （即被吃单或撤单消失的挂量），左右对称构成净 bid pressure。

```
b_prev = np.empty_like(b); b_prev[:, 0] = np.nan; b_prev[:, 1:] = b[:, :-1]
ind_b_up = (b >= b_prev).astype(np.float64)
ind_b_dn = (b <= b_prev).astype(np.float64)
ind_a_dn = (a <= a_prev).astype(np.float64)
ind_a_up = (a >= a_prev).astype(np.float64)
e = ind_b_up * bs - ind_b_dn * bs_prev - ind_a_dn * asz + ind_a_up * as_prev
# 窗口求和：
out[:, col] = e[:, -W:].sum(axis=-1)
```

核心公式——反 Kyle 冲击：给定 W -window log-return r_W 与最后一 tick 净金额 Δamt ,

$$KyleInv_W = \frac{\Delta amt}{\sqrt[3]{|\Delta amt| \cdot \sigma(r_W) + \varepsilon}},$$

直觉是"在活跃度 ($|\Delta amt| \cdot \sigma$) 下，净流动金额能解释多少方向"。




Figure 3: F2 家族内 Pearson 相关性。块内 $|r|$ 平均 0.33（六族之最），说明多尺度 OFI 内部高度共线：同一 EWMA- α 下不同 level 的 OFI，同一 level 下不同 W 的 MLOFI 都几乎平行。LightGBM 受冗余影响小，但对 NN 而言这是冗余特征——后续 NN 路线用 L2 正则 + bagging 抑制。

4.3 家族 F3：订单流强度（45 维）

动机。比赛数据有别于传统 LOB 任务的关键在于：主办方直接给出了 6 类订单事件的强度，limit / market / cancel 三类 CE buy/sell 两侧 = 6 列，并配 $_ind$ / $_acc$ 变体。这是已脱敏的撮合事件计数，远比"由价量反推 OFI"更直接的方向信号。LightGBM 给本家族 35.1% 的 gain，仅次于 F1。

因子清单。

因子 (命名)	维度	含义
lb/la/mb/ma/cb/ca_intst	6	limit-bid / limit-ask / market-bid / market-ask / cancel-bid / cancel-ask 强度
lb/la/mb/ma/cb/ca_ind	6	上述 6 类强度的 indicator 变体
lb/la/mb/ma/cb/ca_acc	6	累计变体
ewma_a α _c_intst	24	6 类 intst 在 EWMA(α) 滤波, $\alpha \in \{0.05, 0.1, 0.3, 0.5\}$
cancel_imb_WW	3	撤单不平衡: $\frac{cb_W}{lb+mb+cb_W} - \frac{ca_W}{la+ma+ca_W}$, $W \in \{20, 50, 100\}$

Table 4: F3 订单流强度 45 维因子。

核心公式——EWMA-滤波订单强度：

$$\tilde{x}_t^{(\alpha)} = \alpha x_t + (1 - \alpha) \tilde{x}_{t-1}^{(\alpha)}, \quad \tilde{x}_0^{(\alpha)} = x_0.$$

通过 `scipy.signal.lfilter` 的 IIR 形式 ($b = [\alpha], a = [1, -(1 - \alpha)]$) 批量计算，避免 Python 循环。

```
def _ewma_last_batch(x, alphas): # x: (N, T)
    out = np.zeros((x.shape[0], len(alphas)))
    for i, a in enumerate(alphas):
        b = np.array([a])
        a_filt = np.array([1.0, -(1.0 - a)])
        zi = ((1.0 - a) * x[:, :1])
        y, _ = lfilter(b, a_filt, x, axis=-1, zi=zi)
        out[:, i] = y[:, -1]
    return out
```

Cancel imbalance 公式：

$$\text{cancel_imb}_W = \frac{\sum_{t-W}^t \text{cb}}{\sum_{t-W}^t (\text{lb} + \text{mb} + \text{cb}) + \varepsilon} - \frac{\sum_{t-W}^t \text{ca}}{\sum_{t-W}^t (\text{la} + \text{ma} + \text{ca}) + \varepsilon}.$$

即买侧撤单占总事件的份额减去卖侧撤单占总事件的份额，正值 = 买侧主动撤更多（卖压隐含上升）。




Figure 4: F3 家族内 Pearson 相关性, 平均 $|r| = 0.18$ 。6 类原始强度 $\times$ 4 个 EWMA- α 形成 24 维 EWMA 块, 同一原始列在不同 α 下高度相关; cancel_imb_W* 三档跨窗口高度相关但与挂单/成交强度近乎正交。

Top 4 全局重要性都在 F3。LightGBM 的 top features: ma_intst (gain 0.9)、mb_intst (0.9)、la_intst (0.6)、lb_intst (0.6)。可见模型最依赖的是 原始 4 维 (market 与 limit 两类买卖强度), EWMA 滤波版本仅作为辅助。

4.4 家族 F4：微结构波动 (29 维)

动机。波动率不仅决定信号强度, 也决定阈值与仓位。SchemeP 用 4 个角度刻画微结构波动: 无符号波动率 $RV = \sum r^2$ 、方向化波动率 signed RV (上行 vs 下行 RV)、跳跃稳健估计二次方变差 (bipower BV)、以及活跃度突发 vol/amt burst (瞬时成交相对窗口均值)。

因子清单。

因子（命名）	维度	含义
volume_delta, amount_delta	2	单 tick 成交量/金额 (log1p 后)
rv_wW	4	$\sqrt{\sum_{t-W}^t r_t^2}$, $W \in \{5, 10, 20, 50\}$, 基于 wmp_lv1+1 的 log-return
signed_rv_WW	3	$(RV_+ - RV_-)/(RV_+ + RV_- + \varepsilon)$, $W \in \{20, 50, 100\}$
rskew_WW	3	log-return 的 sample skewness, clip $[-10, 10]$
signed_bv_WW	3	带符号二次方差 $\frac{\pi}{2} \sum \text{sign}(r_t) r_t r_{t-1} $, 归一化于 RV_W
vol_burst_WW, amt_burst_WW	4	最后一 tick volume/ amount 除以 W-window 均值
rv_ratio_WW _n _WW _d	3	不同窗口长度的 RV 比, $(W_n, W_d) \in \{(5, 50), (20, 100), (50, 100)\}$
jshare_WW	4	跳跃份额 $(RV_W - BV_W)/RV_W$, $W \in \{20, 30, 50, 100\}$
roll_eff_spr_ratio_WW	3	Roll 有效价差 / 报价价差比, $W \in \{30, 50, 100\}$

Table 5: F4 微结构波动 29 维因子。

核心公式——Signed RV:

$$\text{signedRV}_W = \frac{\sum_{t-W}^t r_t^2 \mathbf{1}_{r_t > 0} - \sum_{t-W}^t r_t^2 \mathbf{1}_{r_t < 0}}{\sum_{t-W}^t r_t^2 + \varepsilon} \in [-1, 1].$$

核心公式——Jump share (Barndorff-Nielsen & Shephard):

$$\text{jshare}_W = \max\left(0, \frac{RV_W - BV_W}{RV_W}\right), \quad BV_W = \frac{\pi}{2} \sum |r_t||r_{t-1}|.$$

当价格连续时 $BV \approx RV$, $\text{jshare} \rightarrow 0$; 出现单 tick 跳跃时 $RV \gg BV$, $\text{jshare} \rightarrow 1$ 。

核心公式——Roll 有效价差: $\text{eff} = 2\sqrt{\max(0, -\text{cov}(\Delta P_t, \Delta P_{t-1}))}$, 归一化于报价价差 spread1+1。连续成交里的负自协方差是 bid/ask 跳跃造成的, Roll 估计便是其反推有效价差。




Figure 5: F4 家族内 Pearson 相关性, 平均 $|r| = 0.16$ 。rv_w* 四个窗口高度相关 (无符号波动率本质同源), jshare / signed_rv 与 rv 几乎正交, 提供独立信息。

4.5 家族 F5：窗口统计 (67 维)

动机。本家族是 SchemeP 区别于纯" 原始 LOB + OFI" 基线的胜负手, 也是解决 OOD 漂移的核心。所有因子都是把" 绝对水平" 通过 100-tick 窗口内的统计量 (z-score、quantile rank、median-IQR、长短期 z-score 差) 转成" 相对水平", 跨股票/跨日的基差被压缩到同一动态范围。

因子清单。

因子 (命名)	维度	含义
dualz_c	37	Dual-window z-score: $z_{20} - z_{100}$, 其中 $z_W = (c_t - \mu_W) / \sigma_W$, 对 37 个 base 列做
qrank_W100_c	20	100-tick rank: $\text{rank}(c_t) = \frac{1}{W} \sum \mathbf{1}_{c_s \leq c_t}$, 对 20 个 base 列
mid_ewma_resid_a0.05	1	midprice - EWMA($\alpha = 0.05$) midprice, clip $[-0.05, 0.05]$
adapt_mom_WW	3	自适应动量 $(\text{mid}_t - \text{mid}_{t-W}) / \sigma_W(\text{mid})$
spread_reg_WW	3	稳态化价差 $(\text{spread}_t - \text{median}_W) / \text{IQR}_W$
trade_pers_WW	3	方向持续性 lag-1 autocorr of $\text{sign}(\Delta \text{mid})$

Table 6: F5 窗口统计 67 维因子。

核心公式——Dual-window z-score (决胜 OOD 的"trick"):

$$\text{dualz}(c)_t = \frac{c_t - \mu_{20}(c)}{\sigma_{20}(c) + \varepsilon} - \frac{c_t - \mu_{100}(c)}{\sigma_{100}(c) + \varepsilon}.$$

这是 短窗 z - 长窗 z: 等价于" 当前 tick 相对短期均值偏离 多于长期均值偏离的程度", 对均值水平不敏感

(两个 z 相减消除了全局基差)，对方差也鲁棒（同样除掉了 σ ）。SchemeP 对 37 个 base 列做 dualz，涵盖价差、midprice、size、6 类 intst、bid_diff 等。

```
dz_idx = np.array([col_idx[c] for c in DUAL_Z_COLS])
X_dz = X3d[:, :, dz_idx] # (N, T, 37)
last = X_dz[:, -1, :] # (N, 37)
seg20 = X_dz[:, -20:, :]
seg100 = X_dz[:, -100:, :]
m20, s20 = seg20.mean(1), seg20.std(1, ddof=0)
m100, s100 = seg100.mean(1), seg100.std(1, ddof=0)
z_s = (last - m20) / (s20 + EPS)
z_l = (last - m100) / (s100 + EPS)
dual = np.where(np.isfinite(z_s - z_l), z_s - z_l, 0.0) # (N, 37)
```

Q-rank:

$$\text{qrang}(c)_t = \frac{1}{W} \sum_{s=t-W+1}^t \mathbf{1}_{c_s \leq c_t} \in [0, 1].$$

对重尾因子（如 amount_delta）尤其稳健——分位数对极端值不敏感。

Adapt-mom（自适应动量）:

$$\text{adapt_mom}_W = \frac{\text{mid}_t - \text{mid}_{t-W}}{\sigma_W(\text{mid}) + \varepsilon}, \quad W \in \{20, 50, 100\}.$$

是经典 momentum 除以“近期波动”——相当于把动量用近期波动校准为 z -单位。




Figure 6: F5 家族内 Pearson 相关性，平均 $|r| = 0.088$ （六族之最低）。Dual-z 因子之间几乎相互正交，是 SchemeP 信息密度最高的家族。这一低共线性也支撑了“window-z 是 OOD 决胜 trick”的事实：每个 dualz 都带来独立信息。

4.6 家族 F6：不对称性（74 维）

动机。本家族刻画 买卖两侧的相对差异：广义 OFI（GOFI）量化" 价格档位变化下挂量净流向"，liq-asm 用 top-5 size 比值取对数；*_rate 用滚动平均归一化每档价/量，刻画对自身均值的偏离。

因子清单。

因子（命名）	维度	含义
gofi_WW_lvlk	30	广义 OFI, 按价格变化方向分类挂量增减, $W \in \{5, 20, 60\}$, $k \in \{1..10\}$
liq_asym_top5_WW	4	$\log((1 + \sum_{1..5} \text{bsize}_W) / (1 + \sum_{1..5} \text{asize}_W))$
bid_ratek, ask_ratek	20	主办方滑动平均价格变化率（同侧）
bsize_ratek, asize_ratek	20	主办方滑动平均量变化率（同侧）

Table 7: F6 不对称性 74 维因子。

核心公式——GOFI（广义 OFI）：区别于 MLOFI 严格按" 价格上下行 + 同档量增减"，GOFI 把同价不变时的挂量净变化也算进去：

$$e_t^{(k)} = \underbrace{\mathbf{1}_{b\uparrow} \cdot \text{bs}_t - \mathbf{1}_{b\downarrow} \cdot \text{bs}_{t-1} + \mathbf{1}_{b=}(\text{bs}_t - \text{bs}_{t-1})}_{\text{bid contribution}} + \underbrace{\mathbf{1}_{a\uparrow} \cdot \text{as}_{t-1} - \mathbf{1}_{a\downarrow} \cdot \text{as}_t - \mathbf{1}_{a=}(\text{as}_t - \text{as}_{t-1})}_{\text{ask contribution}}$$

$$\text{GOFI}_{W,k} = \sum_{t=W+1}^t e_s^{(k)}.$$

```

b_lag, a_lag = b[:, :-1], a[:, :-1]
bs_lag, as_lag = bs[:, :-1], asz[:, :-1]
bnow, anow = b[:, 1:], a[:, 1:]
bsnow, asnow = bs[:, 1:], asz[:, 1:]
bid_up = (bnow > b_lag) * bsnow
bid_dn = (bnow < b_lag) * bs_lag
bid_eq = (bnow == b_lag) * (bsnow - bs_lag)
bid_cont = bid_up - bid_dn + bid_eq
# ask 对称：注意 ask_eq 与 bid_eq 符号相反
ask_up = (anow > a_lag) * as_lag
ask_dn = (anow < a_lag) * asnow
ask_eq = (anow == a_lag) * (asnow - as_lag)
ask_cont = ask_up - ask_dn - ask_eq
e_t = bid_cont + ask_cont # 单 tick

```

Liquidity asymmetry:

$$\text{liq_asm}_W^{\text{top5}} = \log \frac{1 + \sum_{k=1}^5 \sum_{s=t-W+1}^t \text{bsize}_s^{(k)}}{1 + \sum_{k=1}^5 \sum_{s=t-W+1}^t \text{asize}_s^{(k)}}, \quad W \in \{5, 20, 50, 100\}.$$

对数比有两个好处：(i) 量纲对称（正/负代表买/卖侧更厚）；(ii) +1 在分子分母防 0 除。




Figure 7: F6 家族内 Pearson 相关性, 平均 $|r| = 0.12$ 。GOFI 30 维子块中跨档/跨窗口相关较强; *_rate 4 个子块 (bid/ask price-rate、bid/ask size-rate) 彼此正交但同子块内 10 档间高度相关。

5. 三类关键预处理

5.1 Sign-preserving log1p (重尾压缩)

针对 amount_delta 这种 6σ 重尾且可正可负的字段, 普通 log 不可用。SchemeP 在 raw last-tick 处理:

$$x \mapsto \text{sign}(x) \cdot \log(1 + |x|).$$

保留方向, 将量纲从 $\sim 10^8$ 压缩到 ~ 18 。

```
raw_last = X3d[:, -1, :].astype(np.float32)
amt_idx = col_idx["amount_delta"]
v = raw_last[:, amt_idx]
raw_last[:, amt_idx] = np.sign(v) * np.log1p(np.abs(v))
```

5.2 Window-z (核心: 跨股票/跨日基差消除)

详见 §4.5 的 dualz 实现。直觉的"为什么": LightGBM 的分裂阈值是绝对值; 如果训练时一只股票的 spread1 集中在 0.001, 测试时另一只股票 (含训练外股票, 构成 OOD) 集中在 0.003, 则训练学到的分裂阈值在测试上全错位。Window-z 通过当 tick 100 ticks 内的 mean/std 把绝对值映射到无量纲 z , 跨股票的"分裂可比性"得到恢复。

公榜 OOD 阶段 PnL 从 -6.65 跃升至 $+35.64$ (增益 $+42.29$), window-z 是其中两个关键 trick 之一。

5.3 Mirror augmentation (镜像增强)

不属于因子构造，但 SchemeP 训练用：把每条 (X, y_{reg}, y_{cls}) 复制一份并 镜像——所有 "bid 类" 与对应 "ask 类" 列对换、 $y_{reg} \rightarrow -y_{reg}$ 、 $y_{cls} \rightarrow 2 - y_{cls}$ 。这迫使模型学到完美的 bid/ask 对称性，避免训练集中某一方向占主导的偏倚，对 50-seed bagging 的 robust 也起到了 "先验对称化" 作用。

6. 特征重要性分析

6.1 全局 Top 40 因子




Figure 8: LGB feature importance Top 40 (按家族着色, gain 越大越重要)。Top 4 全部为 F3 ma/mb/la/lb_intst (market/limit 买卖强度原始 4 维)，紧接着 F1 的 asize1, totalasize, bsize1, avgbid/avgask, totalbsize, asize2。绿色 (F3) + 蓝色 (F1) 几乎垄断 Top 20。

6.2 家族 gain 占比与单因子贡献

家族	因子数	gain 占比 (%)	平均单因子 gain (%)	单因子相对贡献
F1 LOB 派生	105	40.4	0.385	1.42×
F2 多尺度 OFI	50	5.5	0.110	0.41×
F3 订单流强度	45	35.1	0.780	2.89×
F4 微结构波动	29	7.5	0.259	0.96×
F5 窗口统计	67	5.2	0.077	0.29×
F6 不对称性	74	6.3	0.085	0.32×
均值	61.7	16.67	0.270	1.00×

Table 8: 单因子相对贡献 = 家族平均 gain / 全局平均 gain。F3 最高 (2.89×), F5/F6 偏低 (< 0.35×)。

关键观察：F3 的单因子贡献是 F5 的近 10 倍。LightGBM 是一颗树一次只看一个特征做分裂的"贪心"模型，强单因子（F3 原始 intst）有压倒性优势；而 F5 的 z-score 因子"个个不显眼，胜在彼此正交，组合起来形成稳健的决策边界"——这与 g6.3 的 OOD 角度互补：单因子重要性低 ≠ 家族不重要。Ablation 中关掉 F5 时，private board OOD PnL 显著下降。

7. 家族间相关性




Figure 9: 6×6 家族间 block 相关性，块内平均 $|r|$ 。对角线（块内自身）：F2 OFI 0.33 最高（族内高度共线），F5 z-score 0.07 最低（族内近正交）。非对角线：F2↔F6 = 0.176（MLOFI 与 GOFI 同源）、F4↔F1 = 0.063（波动率与价差正相关）、F3↔F4 = 0.065（订单事件强度与波动率适度相关）；其余跨家族 $|r| < 0.07$ 。

结论：

- F2 与 F6 高度互相关 (0.176) ——MLOFI 与 GOFI 同根同源（一为"按价格方向分类挂量增减"，一为"含同价时的挂量变化"），是冗余度最高的家族对。Ablation 显示 F6 全删后模型轻微下降；同时删 F2+F6 才会显著下降，证实两者承担同一信息量的不同切面。
- F5 与所有家族近正交 ($|r| < 0.07$) ——dualz / qrank 通过滚动归一化把绝对水平"扔掉了"，剩下的是相对位置，与任何"绝对水平"族都几乎不相关。这正是 F5 提供独立 OOD 信号的几何解释。

- F1 与 F3 块间 0.035——两个最重要的家族居然几乎正交，说明 LightGBM 同时拿到两者时获得几乎"无冗余"的高信息组合。

8. 讨论与决策记录

为何 SchemeP 在 OOD 上稳健？

1. F5 窗口统计的独立性：dualz/qrank 把跨股票/跨日基差消除，使决策阈值在 OOD 上仍然有效。
2. F1 + F3 的高单因子信息量：在 in-distribution 阶段已经把"该容易的容易点"赚到极限。
3. F2/F6 的多尺度冗余：单尺度 OFI 在不同市场环境下表现飘移，多尺度 + EWMA- α ensemble 给出稳定平均。
4. F4 的跳跃稳健估计：BV/jshare 把跳跃从波动率中分离，让阈值搜索不被极端 tick 干扰。
5. 50-seed bagging + mirror augmentation：把上述六族的方差吸收掉，最终 OOD PnL 从 -6.65 拉到 +35.64。

决策记录：

- 家族划分：本报告 F1 LOB 派生 105 维偏大，因为它把"raw 10 档价/量"全部纳入；如果只算 derived (midprice/spread/wmp 等) 则只剩 35 维，更接近 onepage 摘要里的"~30 维"。本报告选择"全部 370 维都归入某一家族"的口径，更便于审计。
- LGB 模型选择：用 big50_lgb_m7/seed1/model.txt (M7 重训第 1 个种子，370 维全量，未 drop11)，单 seed gain 已与 50-seed 平均 gain 高度一致 (rank corr > 0.95)，用单 seed 报特征重要性具有代表性。
- 相关性采样规模：从 1.47M 行 train 中均匀采样 100 K，计算 370×370 Pearson；与全量计算的 block-mean|r| 差距 < 0.005。
- drop11 vs 全 370：训练时丢弃的 11 维 (如 kyle_lam_W*、liq_asym_top5_W5、qrank_W100_spread*) 大多对应 LGB gain < 0.01 的尾部因子，对 OOD 有微小过拟合风险——drop 后训练更稳。本报告统计基于 370 维口径以保留完整信息。

结论。SchemeP 的 370 维因子并非单纯堆量：六大家族在信息维度上互补 (F1/F3 提供强单因子绝对信号、F5 提供近正交的相对信号、F2/F6 提供多尺度 OFI 稳健性、F4 提供波动率与跳跃稳健性)，配合 sign-preserving loglp、window-z、mirror augmentation 三类预处理以及 50-seed bagging，是良文杯 2026 公榜/私榜双第一的核心因子工程基础。