

因子工程报告 (v2)

良文杯 2026 LOB 中间价方向预测—SchemeP 共 370 维因子拆解
新增 F0 原始 154 维各类型贡献分析 & NN 训练管线 NaN 处理

史景喆 (清华大学)

团队：超级回天什么时候上映 | 公榜 #1 (+35.64) | 私榜 #1

2026 年 5 月

1. 摘要

本报告对良文杯 2026 决赛冠军方案 SchemeP 的特征体系做完整技术性拆解。SchemeP 在 $T = 100$ tick 因果窗口上构造 370 维特征向量，其中 154 维原始字段 (F0) + 216 维派生因子 (F1-F6 中除原始字段外的派生部分)。

核心结论 (v2 新增)：把 370 维按"是否原始 vs 派生"切，LightGBM 的特征重要性显示 F0 原始 154 维占总 gain 70.9%，派生 216 维仅占 29.1%；在 F0 内部最强单一类别是 order flow intensity (*_intst)，6 维贡献 raw-gain 31.3%，单因子 ma_intst gain = 0.95 居全特征第一。这一观察直接挑战了"派生因子是主力"的直觉——派生层的真实角色更接近"OOD 稳健化器"，而非"信息核心"。

进一步按语义将 370 维归入六大家族 (F1~F6)：F1 LOB 派生 (105 维，含 10 档原始价/量)、F2 多尺度 OFI (50 维，派生)、F3 订单流强度 (45 维，含 18 维原始 + 27 维派生)、F4 微结构波动 (29 维，派生)、F5 窗口统计 (67 维，派生)、F6 不对称性 (74 维，含 40 维原始 *_rate)。LightGBM 给 F1 占 gain 40.4%、F3 占 gain 35.1%，两者合计 75.5%。家族间最低共线性是 F5 (块内 $|r| = 0.07$ 、跨家族 $|r| < 0.07$)，这一独立性是 OOD 稳健性的几何基础。

报告同时新增一节 g6 说明 NN 训练管线对 NaN 的处理：window-z 路径用 np.nanmean / nanstd 算统计量、归一化后用 nan_to_num(nan=0, posinf=10, neginf=-10) + clip(-10, 10)，旁路 (无 window-z) 在 raw scale 直接 nan_to_num(nan=0)；LGB 路径完全不做 NaN 处理 (自带 missing 路由)。

2. 数据基底与原始 154 维字段

原始字段 (154 维)：来自盘口 snapshot parquet，每 tick 包含

- OHLC 与单 tick 增量：open, high, low, close, volume_delta, amount_delta (6 维)；
- 10 档买卖盘价 bidk / askk (20 维) 与挂单量 bsizek / asizek (20 维)， $k \in \{1..10\}$ ；
- 行情衍生量 avgbid, avgask, totalbsize, totalasize (4 维)、bid_mean, ask_mean, bsize_mean, asize_mean (4 维)；
- 主办方提供的中位价与价差 midpricek, spreadk (20 维)、cumsread, imbalance (2 维)、跨档价差 bid_diffk, ask_diffk (20 维)；
- 六类订单事件强度——挂单 lb/la_intst、成交 mb/ma_intst、撤单 cb/ca_intst 及其 _ind / _acc 变体 (18 维)；
- 主办方滑动平均变化率 bid_ratek / ask_ratek / bsize_ratek / asize_ratek (40 维)。

派生因子 (216 维)：在长度 $T = 100$ 的滑动窗口上一次性向量化 (sliding_window_view) 后批量计算，按 stage 顺序拼接：

$$\underbrace{X_{\text{raw}}}_{154} \oplus \underbrace{X_{T3}}_{69} \oplus \underbrace{X_{S1}}_{54} \oplus \underbrace{X_{S2}}_{59} \oplus \underbrace{X_{S3}}_{14} \oplus \underbrace{X_{S5}}_{20} = 370.$$

T3 含 MLOFI / WMP / RV / EWMA-intst, Stage 1 含 dual-z / signed-RV / Kyle / EWMA-OFI, Stage 2 含 qrank / skew / GOFI / Kyle- λ / vol-burst, Stage 3 含 EWMA 残差 / RV ratio / jump-share / cancel-imb / Roll 效价比, Stage 5 含 adaptive-momentum / OFI-toxicity / signed-bipower / spread-regime / trade-persistence / liq-asm。

标签：5 个 horizon $h \in \{5, 10, 20, 40, 60\}$ 的 3 类方向 (涨 / 平 / 跌)。比赛主力使用 $h = 60$ 。

硬约束 (CRITICAL CONSTRAINTS): 评测时 date=0、sym 0-4 可含训练外股票、测试点顺序被打乱。因此所有 370 个因子都满足: (i) 不显式使用 date / sym; (ii) 每条样本独立可算, 不依赖跨样本状态; (iii) sym-agnostic, 不嵌入 sym embedding 或 sym-conditional 归一化。

3. F0: 原始 154 维各类型贡献分析

3.1 设计逻辑

把 370 维按"是否派生"切, 可以回答一个朴素而重要的问题: **我们花了 216 维派生工程, 到底带来了多少额外 gain?** 为此把 raw 154 维按字段语义拆成 17 个类型 (OHLC、bid 价、ask 价、bid 量、ask 量、LOB 聚合、midprice、spread、bid_diff、ask_diff、LOB simple aggregates、价格 rate、量 rate、3 类 order-flow × 6 类事件), 统计每个类型的 LGB gain 占比与单因子 gain。计算基于 big50_lgb_m7/seed=1 模型 (M7 重训第 1 个种子, 370 维全量)。

3.2 结果一: F0 vs 派生整体占比




Figure 1: 原始 154 维 (F0) 占 LGB 总 gain 70.9%, 派生 216 维仅占 29.1%。本图直接表明: 派生因子对单一 LGB 模型的边际信息贡献并不大; 其真正价值在于 OOD 稳健化 (详见 §10)。

3.3 结果二：F0 内 17 个类型的 gain 分解

类型	#feat	sum gain	share raw (%)	avg per feat
order flow intensity (intst)	6	3.032	31.30	0.505
LOB aggregate (avgbid/avgask/total*size)	4	1.453	15.00	0.363
order flow indicator (ind)	6	0.801	8.27	0.133
ask size L1-L10	10	0.699	7.22	0.070
bid size L1-L10	10	0.662	6.83	0.066
LOB simple aggregates (bid_mean/imbalance/cumspread/...)	6	0.595	6.14	0.099
OHLC	4	0.535	5.52	0.134
ask price L1-L10	10	0.382	3.95	0.038
bid price L1-L10	10	0.372	3.84	0.037
size rate (bsize/ask_rate1-10)	20	0.350	3.62	0.018
ask_diff L1-L10	10	0.286	2.95	0.029
bid_diff L1-L10	10	0.246	2.54	0.025
order flow acceleration (acc)	6	0.125	1.29	0.021
spread levels	10	0.059	0.61	0.006
price rate (bid/ask_rate1-10)	20	0.046	0.47	0.002
midprice levels	10	0.039	0.40	0.004
volume / amount delta	2	0.006	0.06	0.003
合计 raw 154	154	9.687	100.00	0.063

Table 1: F0 raw 154 维按字段语义分组后的 LGB gain 占比与单因子均值。share 列以 raw-154 内部总 gain 为分母（即 9.687）。




Figure 2: F0 raw 154 维：17 个类型 LGB gain 占比（以 raw-total = 100% 标定），右侧标注 占比、维度数、平均单因子 gain。intst 6 维一骑绝尘（31.3%）；最末三类（midprice、price rate、volume/amount delta）几乎是死特征。

3.4 结果三：order-flow 6×3 子矩阵

进一步把 18 维 order-flow 拆成 6 类事件 (lb / la / mb / ma / cb / ca) × 3 类变体 (intst / ind / acc)：




Figure 3: F0 order-flow 18 维 gain heatmap。ma_intst (市价买) gain = 0.945 全因子第一, mb_intst (市价卖) 0.860 第二。所有 6 类的 _acc 变体几乎死特征 (<0.05); cb/ca (撤单) 3 维 × 3 变体合计 gain <0.01 , 撤单"原始"信号 LGB 直接忽略, 撤单 imbalance 已被 F3 派生的 cancel_imb_W* 接管。

3.5 核心观察

- Order flow intensity (*_intst) 6 维是 F0 信息核心: 单因子最强 (ma_intst = 0.95、mb_intst = 0.86), 6 维合计占 raw-gain 31.3%。这是已脱敏的撮合事件计数, 比"由价量反推 OFI"直接得多。
- LOB aggregate (4 维) 比 10 档原始价格更有用: 4 维占 raw-gain 15.0%、平均单因子 gain 0.363, 远高于 10 档 ask price (3.95%、0.038)。原因: 聚合量 totalasize / totalbsize / avgbid / avgask 已把 10 档信息压缩到 1 维有效信号, 避免了"10 档分散重要性"。
- midprice / spread / price_rate 几乎死特征 (每 feat <0.01): 合计 40 维但只贡献 raw-gain 1.5%。原因: midprice 严重共线 (10 档 midprice 之间 $|r| > 0.99$), spread 在标准化前是绝对值 (受 sym 基差污染), price_rate 已被 LOB derivative 主导。
- volume / amount delta 几乎为 0 (0.06% raw-gain): 原始单 tick 净流量信号已被 *_intst 完整接管——后者是更精细的"按事件类型拆分"版本。这说明 F3 订单流强度的 6 类 intst 把 raw flow 信息全部"吃掉"了。
- ind/acc 变体相比 intst 大幅退化: 6 类 *_ind 合计 8.27% raw-gain, *_acc 仅 1.29%。intst 的"强度"比"指示"或"加速度"信息更丰富。

4. 家族总览 (F1-F6)

家族	因子数	占总数 (%)	LGB gain 占比 (%)
F1 LOB 派生	105	28.4	40.4
F2 多尺度 OFI	50	13.5	5.5
F3 订单流强度	45	12.2	35.1
F4 微结构波动	29	7.8	7.5
F5 窗口统计	67	18.1	5.2
F6 不对称性	74	20.0	6.3
合计	370	100	100

Table 2: 六大家族因子数与 LightGBM 特征重要性 (gain, h=60 M7 模型 seed=1)。F1 + F3 = 75.5%。




Figure 4: 各家族因子数与 gain 占比对比。F1 (28.4% 因子 / 40.4% gain) 与 F3 (12.2% 因子 / 35.1% gain) 单因子贡献最强；F5 (18.1% / 5.2%) 单因子最弱但近正交（族内 $|r| = 0.07$ ），承担 OOD 稳健化。

注意：F0 与 F1-F6 不互斥。F0 是按"原始 vs 派生"的 binary 切分，F1-F6 是按"语义功能"的 6-way 切分。每一维 raw feature 都同时属于 F0 和某个 F_i （例： $ma_intst \in F0$ 且 $\in F3$ ； $bid1 \in F0$ 且 $\in F1$ ）。两种视角互补：F0 视角回答"派生工程值不值"，F1-F6 视角回答"信息维度上各家族的角色"。

5. F1-F6：派生因子六大家族

5.1 家族 F1：LOB 派生 (105 维)

动机。盘口 snapshot 自身的价格水平、挂单深度与中位价是任何方向预测的最基本输入。本家族包含原始 OHLC、10 档买卖盘价/量、价差、中位价、加权微价格 WMP，以及订单簿层间结构 bid_diff / ask_diff （同侧相邻档位间价格差）。它们刻画"当下盘口长什么样"，是 F2-F6 衍生因子的基底。

因子清单。OHLC 4 + bid_k / ask_k 20 + $bsize_k / asize_k$ 20 + $avgbid / avgask / totalbsize / totalasize$ 4 + $bid_mean / ask_mean / bsize_mean / asize_mean$ 4 + $midprice_k$ 10 + $spread_k$ 10 + $cumspread / imbalance$ 2 + bid_diff_k / ask_diff_k 20 + wmp_lvl_k 10 + $wmp_balance_12$ 1 = 105 维。

核心代码——WMP（加权微价格）：

```
for k in T3_LOB_LEVELS: # 1..10
    b = X3d[:, :, col_idx[f"bid{k}"]]
    a = X3d[:, :, col_idx[f"ask{k}"]]
    bs = X3d[:, :, col_idx[f"bsize{k}"]]
    asz = X3d[:, :, col_idx[f"asize{k}"]]
    denom = bs + asz
    wmp_normal = (a * bs + b * asz) / np.where(denom == 0, 1.0, denom)
    wmp_fallback = (a + b) / 2.0
    wmp = np.where(denom == 0, wmp_fallback, wmp_normal)
    out[:, col] = wmp[:, -1]; col += 1
out[:, col] = wmp_per_level[0][:, -1] - wmp_per_level[1][:, -1] # wmp_balance_12
```

WMP 分子用 $ask * bsize + bid * asize$ ("短缺侧权重"), 符合 Stoikov 微价格直觉, 挂单越少的一侧把 WMP 拉得越接近其报价。




Figure 5: F1 家族内 Pearson 相关性 (采样 10 万行 train)，平均 $|r| = 0.154$ 。10 档同名因子 (如 bid1..bid10) 形成明显对角块；midprice k 与 wmp_lv k 高度相关 (同向价值)。

5.2 家族 F2：多尺度 OFI (50 维)

动机。 订单流不平衡 (OFI, Cont 2014) 是预测短期方向的最强信号家族。SchemeP 在多窗口 ($W \in \{5, 20, 60\}$ for MLOFI; $W \in \{50, 100\}$ for Kyle/toxicity) 与多 EWMA 半衰期 ($\alpha \in \{0.05, 0.1, 0.3, 0.5\}$) 乘积空间内构造 50 维 OFI 表达。

因子清单。 $\text{omlofi_WW_lvl}k \ 30 + \text{ewma_ofi_}\alpha_\text{lvl}k \ 12 + \text{kyle_inv_WW} \ 2 + \text{kyle_lam_WW} \ 2 + \text{ofi_tox_lvl}k_WW \ 4 = 50$ 维。

核心公式——MLOFI (Cont 2014 multi-level OFI)： 对每一档 k ,

$$e_t^{(k)} = \mathbf{1}_{b_t^{(k)} \geq b_{t-1}^{(k)}} \text{bs}_t^{(k)} - \mathbf{1}_{b_t^{(k)} \leq b_{t-1}^{(k)}} \text{bs}_{t-1}^{(k)} - \mathbf{1}_{a_t^{(k)} \leq a_{t-1}^{(k)}} \text{as}_t^{(k)} + \mathbf{1}_{a_t^{(k)} \geq a_{t-1}^{(k)}} \text{as}_{t-1}^{(k)}.$$

再做窗口求和 $\text{MLOFI}_{t,W}^{(k)} = \sum_{s=t-W+1}^t e_s^{(k)}$ 。 b 上行 (或持平) 时贡献 +bs; b 下行时减去前一档 bs (即被吃单或撤单消失的挂量)，左右对称构成净 bid pressure。

核心公式——反 Kyle 冲击： $\text{KyleInv}_W = \frac{\Delta \text{amt}}{\sqrt[3]{|\Delta \text{amt}| \cdot \sigma(r_W) + \varepsilon}}$ ，直觉是 "在活跃度下，净流动金额能解释多少方向"。




Figure 6: F2 家族内 Pearson 相关性, 平均 $|r| = 0.33$ (六族之最)。多尺度 OFI 内部高度共线：同一 EWMA- α 下不同 level 的 OFI、同一 level 下不同 W 的 MLOFI 都几乎平行。

5.3 家族 F3：订单流强度 (45 维)

动机。比赛数据有别于传统 LOB 任务的关键在于：主办方直接给出了 6 类订单事件的强度，limit / market / cancel 三类 (E buy/sell 两侧 = 6 列，并配 `_ind` / `_acc` 变体。LightGBM 给本家族 35.1% 的 gain，其中 6 维 * `_intst` 单独贡献 22.2% 总 gain (即 31.3% raw-gain，见 F0 章节)。

因子清单。lb/la/mb/ma/cb/ca_intst 6 + `_ind` 6 + `_acc` 6 + ewma_ α _c_intst 24 + cancel_imb_WW 3 = 45 维。

核心公式——EWMA-滤波订单强度： $\hat{x}_t^{(\alpha)} = \alpha x_t + (1 - \alpha) \hat{x}_{t-1}^{(\alpha)}$ 。通过 `scipy.signal.lfilter` 的 IIR 形式 ($b = [\alpha], a = [1, -(1 - \alpha)]$) 批量计算。

Cancel imbalance:

$$\text{cancel_imb}_W = \frac{\sum \text{cb}}{\sum (\text{lb} + \text{mb} + \text{cb}) + \varepsilon} - \frac{\sum \text{ca}}{\sum (\text{la} + \text{ma} + \text{ca}) + \varepsilon}.$$




Figure 7: F3 家族内 Pearson 相关性, 平均 $|r| = 0.18$ 。6 类原始强度 $\times$ 4 个 EWMA- α 形成 24 维 EWMA 块; cancel_imb_W* 三档跨窗口高度相关但与挂单/成交强度近乎正交。

Top 4 全局重要性都在 F3。LightGBM top features: ma_intst (gain 0.95)、mb_intst (0.86)、la_intst (0.65)、lb_intst (0.57)。模型最依赖的是 原始 4 维 (market 与 limit 两类买卖强度), EWMA 滤波版本仅作为辅助。

5.4 家族 F4：微结构波动 (29 维)

动机。波动率不仅决定信号强度, 也决定阈值与仓位。SchemeP 用 4 个角度刻画微结构波动: 无符号波动率 $RV = \sum r^2$ 、方向化波动率 signed RV、跳跃稳健估计二次方变差 (bipower BV)、以及 活跃度突发 vol/amt burst。

因子清单。volume_delta/amount_delta 2 + rv_wW 4 + signed_rv_WW 3 + rskew_WW 3 + signed_bv_WW 3 + vol/amt_burst_WW 4 + rv_ratio 3 + jshare_WW 4 + roll_eff_spr_ratio_WW 3 = 29 维。

核心公式: signed RV = $(RV_+ - RV_-)/(RV_+ + RV_-) \in [-1, 1]$; jump share = $\max(0, (RV_W - BV_W)/RV_W)$, $BV_W = \frac{\pi}{2} \sum |r_t| |r_{t-1}|$ (价格连续时 $BV \approx RV$, 跳跃时 $RV \gg BV$); Roll 有效价差 = $2\sqrt{\max(0, -\text{cov}(\Delta P_t, \Delta P_{t-1}))}$ 。




Figure 9: F5 家族内 Pearson 相关性, 平均 $|r| = 0.07$ (六族之最低)。Dual-z 因子之间几乎相互正交, 是 SchemeP 信息密度最高的家族。

5.6 家族 F6: 不对称性 (74 维)

动机。本家族刻画 买卖两侧的相对差异: 广义 OFI (GOFI) 量化" 价格档位变化下挂量净流向", liq-asym 用 top-5 size 比值取对数; *_rate 用滚动平均归一化每档价/量。

因子清单: $\text{gofi_WW_lvlk } 30 + \text{liq_asym_top5_WW } 4 + \text{bid_ratek/ask_ratek } 20 + \text{bsize_ratek/asize_ratek } 20 = 74 \text{ 维}。$

核心公式——GOFI: 区别于 MLOFI 严格按" 价格上下行 + 同档量增减", GOFI 把同价不变时的挂量净变化也算进去:

$$e_t^{(k)} = (\mathbf{1}_{b\uparrow}bs_t - \mathbf{1}_{b\downarrow}bs_{t-1} + \mathbf{1}_{b=}(bs_t - bs_{t-1})) + (\mathbf{1}_{a\uparrow}as_{t-1} - \mathbf{1}_{a\downarrow}as_t - \mathbf{1}_{a=}(as_t - as_{t-1})).$$




Figure 10: F6 家族内 Pearson 相关性，平均 $|r| = 0.12$ 。GOFI 30 因子块跨档/跨窗口相关较强；*_rate 4 个子块彼此正交，但同子块内 10 档间高度相关。

6. NN 训练管线的 NaN 处理

NN 与 LGB 的关键差异之一是：NN 不能容忍 NaN/Inf，否则前向出 nan loss、反向梯度爆炸；而 LGB 自带 missing value 路由（每个 split 学一个 NaN-direction）。SchemeP 的 NN 管线对 NaN 做严格的“两层兜底”。

6.1 数据集本身的 NaN 分布

完整 SchemeP cache（ablation_runs/cache_log1p）在 154 维原始字段上扫描：

- 1192 / 1200 个文件无 NaN（绝大多数 tick 的盘口 10 档都填满）；
- 8 个文件（涨停日 / 跌停日）深档 ask 或 bid 出现少量缺失——盘口被打穿、深档无报价；
- 派生 216 维由 sliding_window_view + 向量化算式产出，所有 NaN 已在派生公式里用 np.where（denom==0, fallback, normal）兜过一次（如 WMP fallback 到普通 mid，dualz 用 np.isfinite 兜底）；
- 因此进入 NN 管线时，预期 NaN 数 $\ll 10^{-5}$ 占比，但不能假设没有——必须设最后一层兜底。

6.2 主路径：window-z 开启时的 NaN 处理

代码位置 ablation_runs/rerun_13rows.py:271-285：

```
# 5. window-z (global mu/sd on train)
if cfg["wz"]:
    mu = np.nanmean(tr["X"], axis=0).astype(np.float32)
    sd = np.maximum(np.nanstd(tr["X"], axis=0),
                    1e-6).astype(np.float32)

    def zsc(X):
        out = (X - mu) / sd
        np.nan_to_num(out, copy=False,

# (1) nan-aware mean
# (1) nan-aware std
# (2) clamp sd >= 1e-6
# (3) standardize
```

```

nan=0.0, posinf=10.0, neginf=-10.0) # (4) NaN->0, +-inf->+-10
np.clip(out, -CLIP, CLIP, out=out) # (5) clip to [-10, 10]
return out.astype(np.float32)
tr["X"] = zsc(tr["X"]); va["X"] = zsc(va["X"]); te["X"] = zsc(te["X"])

```

五步策略与理由:

1. `np.nanmean` / `nanstd` 算 train 全局统计量——若用普通 `mean`, 任意一行有 NaN 都会污染整列均值; `nan-aware` 版本只忽略缺失格子。
2. `sd clamp` 到 $\geq 10^{-6}$ ——防止常数列 (如某 `sym` 在某窗口 `spread=const`) 导致 0 除。
3. 用 train 的 μ, σ 直接套到 val/test——保证三集统计同口径, 避免 train/val/test 分布偏移。
4. `nan_to_num(nan=0)`: 归一化之后 NaN 已是"未知偏离度", 置 0 = "等于均值" = 最保守的 `mean-imputation`。
`posinf=10, neginf=-10`: 极端值映射到 ± 10 (即 $\pm \text{CLIP}$), 与下一步 `clip` 兜底一致。
5. `clip(-10, 10)`: 极端 outlier (如 `sigma=0` 时被除爆的样本) 压回边界, 避免梯度爆炸。`CLIP=10` 来源于 `rerun_13rows.py:49`。

6.3 旁路: 无 window-z 的 raw-scale NaN 处理

代码 `rerun_13rows.py:283-288`:

```

else:
    for arr in (tr["X"], va["X"], te["X"]):
        np.nan_to_num(arr, copy=False, nan=0.0) # raw scale: NaN -> 0
    mu = np.zeros(tr["X"].shape[1], dtype=np.float32)
    sd = np.ones(tr["X"].shape[1], dtype=np.float32)

```

这是 保守旁路: raw scale 下 `NaN` $\rightarrow 0$ 在数值上未必"等于均值" (因为 0 不是经验均值), 但对极少数 NaN 的样本来说, 仍然是"该位特征贡献 0"——比让前向出 NaN 强。这条路径主要用在控制实验 (消融 `window-z` 看效果), 不是主提交。

6.4 与 LGB 路径的对比

模型	NaN 处理	理由
LGB	完全不动	LightGBM 每个 split 学一个 NaN-direction, 把缺失当第三个 bin: 对该 feat = NaN 的样本, 整体路由到左/右子树之一。比手动 <code>imputation</code> 信息量更高。
NN (主路径)	<code>nanmean</code> / <code>nanstd</code> $\rightarrow$ <code>zsc</code> $\rightarrow$ <code>nan_to_num(0)</code> $\rightarrow$ <code>clip</code>	NN 前向不能容忍 NaN; 归一化后 <code>NaN</code> $\rightarrow 0$ = "等于 train 均值", 保守。
NN (旁路 raw)	<code>nan_to_num(0)</code> 直接在 raw scale	不等于均值 ($0 \neq \mu$), 但仍能保证前向有限值。控制实验用。

Table 3: LGB 与 NN 两条管线对 NaN 的处理对比。

关键工程教训: `np.nanmean` 与 `np.mean` 一字之差, 决定了"是否被 NaN 污染全列"。SchemeP 早期版本曾因为漏掉 `nan*` 前缀, 导致某一列均值变成 NaN $\rightarrow$ 全部样本归一化后变成 NaN $\rightarrow$ 训练崩溃。这是 NN-on-LOB 工程里最容易 `misstep` 的一行代码。

7. 三类关键预处理

7.1 Sign-preserving log1p (重尾压缩)

针对 `amount_delta` 这种 6σ 重尾且可正可负的字段: $x \mapsto \text{sign}(x) \cdot \log(1 + |x|)$ 。保留方向, 将量纲从 $\sim 10^8$ 压缩到 ~ 18 。

```

raw_last = X3d[:, -1, :].astype(np.float32)
amt_idx = col_idx["amount_delta"]
v = raw_last[:, amt_idx]
raw_last[:, amt_idx] = np.sign(v) * np.log1p(np.abs(v))

```

7.2 Window-z (跨股票/跨日基差消除)

详见 §5.5 dualz 实现。**为什么对 OOD 关键：**LightGBM 分裂阈值是 绝对值；若 train 一只股票 spread1 $\sim 10^{-3}$, test OOD 股票 spread1 $\sim 3\times 10^{-3}$, 则训练阈值在测试上全错位。Window-z 把绝对值映射到无量纲 z , "分裂可比性" 得到恢复。

公榜 OOD 阶段 PnL 从 -6.65 跃升至 $+35.64$ (增益 $+42.29$), window-z 是其中两个关键 trick 之一。

7.3 Mirror augmentation (镜像增强)

每条 $(X, y_{\text{reg}}, y_{\text{cls}})$ 复制一份并 镜像：所有 "bid 类" 与对应 "ask 类" 列对换、 $y_{\text{reg}} \rightarrow -y_{\text{reg}}$ 、 $y_{\text{cls}} \rightarrow 2 - y_{\text{cls}}$ 。强制模型学到完美的 bid/ask 对称性，对 50-seed bagging robust 起到 "先验对称化" 作用。

8. 特征重要性分析

8.1 F0 vs F1-F6 的双视角总览

切分视角	类别	gain	占比 (%)	备注
F0 vs derived (binary)	F0 raw 154		70.9	派生工程并非 gain 主力
	derived 216		29.1	主要承担 OOD 稳健化
F1-F6 (6-way 语义)	F1 LOB 派生 105		40.4	含原始 OHLC + 10 档
	F2 多尺度 OFI 50		5.5	全派生
	F3 订单流强度 45		35.1	含 18 维原始 *_intst/ind/acc
	F4 微结构波动 29		7.5	主要派生
	F5 窗口统计 67		5.2	全派生, OOD 主力
	F6 不对称性 74		6.3	含 40 维原始 *_rate

Table 4: 两种视角下的 gain 占比。注意 F0 与 F_i 是不同的切分维度，不互斥。

8.2 全局 Top 40 因子




Figure 11: LGB feature importance Top 40 (按家族着色)。Top 4 全部为 F3 ma/mb/la/lb_intst (原始 6 维 * _intst 中的 4 个); 紧接着 F1 的 asize1, totalasize, bsize1, avgbid/avgask, totalbsize, asize2 (全部为原始字段)。Top 20 几乎全部是 F0 原始字段。

8.3 家族 gain 占比与单因子贡献

家族	因子数	gain 占比 (%)	平均单因子 gain (%)	单因子相对贡献
F1 LOB 派生	105	40.4	0.385	1.42×
F2 多尺度 OFI	50	5.5	0.110	0.41×
F3 订单流强度	45	35.1	0.780	2.89×
F4 微结构波动	29	7.5	0.259	0.96×
F5 窗口统计	67	5.2	0.077	0.29×
F6 不对称性	74	6.3	0.085	0.32×
均值	61.7	16.67	0.270	1.00×

Table 5: 单因子相对贡献 = 家族平均 gain / 全局平均 gain。F3 最高 (2.89×), F5/F6 偏低 (< 0.35×)。

关键观察: F3 的单因子贡献是 F5 的近 10 倍。LightGBM 是一颗树一次只看一个特征做分裂的"贪心"模型, 强单因子 (F3 原始 intst) 有压倒性优势; 而 F5 的 z-score 因子"个个不显眼, 胜在彼此正交, 组合起来形成稳健的决策边界"。单因子重要性低 ≠ 家族不重要。

9. 家族间相关性




Figure 12: 6×6 家族间 block 相关性, 块内平均 $|r|$ 。对角线: F2 0.33 最高 (族内高度共线), F5 0.07 最低 (族内近正交)。非对角线: F2↔F6 = 0.176 (MLOFI 与 GOFI 同源)、F4↔F1 = 0.063、F3↔F4 = 0.065; 其余跨家族 $|r| < 0.07$ 。

结论:

- F2 与 F6 高度互相关 (0.176) ——MLOFI 与 GOFI 同根同源。Ablation 显示 F6 全删后模型轻微下降; 同时删 F2+F6 才会显著下降。
- F5 与所有家族近正交 ($|r| < 0.07$) ——dualz / qrank 通过滚动归一化把绝对水平"扔掉"了, 剩下的是相对位置。这是 F5 提供独立 OOD 信号的几何解释。
- F1 与 F3 块间 0.035——两个最重要的家族几乎正交, LightGBM 同时拿到两者时获得几乎"无冗余"的高信息组合。

10. 讨论：因子工程在 OOD 上稳健的根因

核心张力：F0 章节表明 原始 154 维占 LGB gain 70.9%，那派生 216 维是不是"白做了"？答案是：单看单 LGB 模型 in-distribution 的 gain，派生贡献边际；但 OOD PnL 与多模型 ensemble 上，派生层（尤其 F5）撑起了稳健性。

1. **F5 窗口统计的独立性是 OOD 主力：**dualz / qrank 通过滚动归一化把跨股票/跨日基差消除，决策阈值在 OOD 上仍有效。F5 单因子 gain 平均 0.077（最低），但与所有家族近正交 ($|r| < 0.07$)，它的 5.2% gain 是"无冗余 5.2%"。
2. **F1 + F3 的高单因子信息量是 ID 主力：**F3 * _intst 6 维占 raw-gain 31.3%，F1 LOB aggregate 4 维占 raw-gain 15.0%。在 in-distribution 阶段已经把"该容易的容易点"赚到极限。
3. **F2 / F6 的多尺度冗余：**单尺度 OFI 在不同市场环境下表现飘移，多尺度 + EWMA- α ensemble 给出稳定平均。Ablation 中 F2+F6 同时删除会显著下降。
4. **F4 的跳跃稳健估计：**BV / jshare 把跳跃从波动率中分离，让阈值搜索不被极端 tick 干扰。
5. **50-seed bagging + mirror augmentation：**把上述六族的方差吸收掉，最终 OOD PnL 从 -6.65 拉到 +35.64。
6. **NN NaN 处理的工程稳健性：**window-z 主路径用 nan-aware 统计量 + 归一化后 nan_to_num + clip 三层兜底，保证训练全程无 NaN loss（LGB 则完全不动 NaN，由内置 missing 路由处理）。

决策记录（v2 修订）：

- F0 视角必要性：v1 报告完全没有 F0 vs derived 视角，给读者错误印象"派生 216 维是主力"。v2 通过 g3 章节明确 F0 占 70.9%，与"派生工程更多承担 OOD 稳健化"的真实角色保持一致。
- 家族划分：F1 LOB 派生 105 维偏大，因为它把"raw 10 档价/量"全部纳入；选择"全部 370 维都归入某一家族"的口径，更便于审计。
- LGB 模型选择：用 big50_lgb_m7/seed1/model.txt (M7 重训第 1 个种子，370 维全量，未 drop11)，单 seed gain 已与 50-seed 平均 gain 高度一致 (rank corr > 0.95)。
- 相关性采样规模：从 1.47M 行 train 中均匀采样 100 K 计算 370×370 Pearson；与全量计算的 block-mean $|r|$ 差距 < 0.005。

结论。SchemeP 的 370 维因子并非单纯堆量：

- F0 raw 154 维是单 LGB 模型 gain 主力 (70.9%) ——其中 *_intst 6 维 + LOB aggregate 4 维已占 raw-gain 46.3%；
- 派生 216 维是 OOD 稳健化器，单看 gain 占比 29.1% 边际，但 F5 z-score 的近正交性是跨股票/跨日泛化的几何基础；
- 配合 sign-log1p、window-z、mirror augmentation 三类预处理，NN 管线的 nan-aware 统计 + nan_to_num + clip 三层兜底，以及 50-seed bagging，是良文杯 2026 公榜/私榜双第一的核心因子工程基础。