

良文杯：比赛方案 & 基于 AI Agent 的研究方案

792 队 **史景喆**（清华大学-超级回天什么时候上映队）

私榜累计收益率 **+41.61 #1**

第一部分：比赛方案

问题设定与评分——带交易成本的「期望收益预测」题

数据

- ▶ 5 只匿名 A 股 $\times$ 120 交易日 $\times$ 4002 ticks (3 秒/tick)
- ▶ 154 维原始字段: OHLC / **10 档 LOB** / **6 类订单流** (intst, ind, acc) / 衍生 spread & imbalance
- ▶ 1200 parquet, $\sim$ 474 MB; 8 文件涨停日深档 ask 含少量 NaN (pipeline isfinite 兜底)

评分


- ▶ 动作 $\hat{a} \in \{0, 1, 2\}$, 仅买/卖扣 $\sim 0.02\%$ 双边手续费
- ▶ 总分 $\text{Score} = \max_{h \in \{5, 10, 20, 40, 60\}} \sum_i \text{pnl}_i^{(h)}$
- ▶ **本文以 $h=60$ 为主线**

评测端 3 条硬约束

- ① date 被置 0
- ② 测试点顺序被打乱
- ③ sym 0–4 可能含训练外股票 $\Rightarrow$ sym-agnostic

正确性 · 有效性 · 范化性

方案 Pipeline 一览





本地 Evaluation 设置

Eval setting	划分方式	OOD 维度 & 用途
Train-Val-Test	Train 日期 0–79 / Val 80–95 / Test 96–119 (单一切分, 严格时间顺序)	日期 OOD; early stop + 阈值搜索在 val; test 完全冻结 (zero-tune), 最终评分
LOSO-date	K-fold by date: 120 天划成 K 块 (K=5 或合并 442k 样本), 每折训练其它 K-1 块、eval 留出块	日期 OOD; stock 全部 in-sample; 用于早期特征筛选, OOF 预测拼接
LOSO-stock	5-fold by stock: 5 只股票各做 1 fold, 训练用其余 4 只 $\times$ 所有 120 天, eval 留出 1 只 $\times$ 所有日期	股票 OOD; 验证 sym-agnostic 假设 (评测时可能含训练外股票)

PPT 与表格里报的 *PnL*, 若未特别说明, 均为 **Train-Val-Test** setting 下的 *Test PnL*。

因子工程：六大家族 (105+50+45+29+67+74 = 370 → KS drop 11 → 359 维)

- ▶ **F1 LOB 派生** (94 raw + 11 派生 = 105 维, **gain 40.4%**)
OHLC, 10 档 bid/ask 价 + 挂单量, agg (avgbid/avgask/total*size), 4 mean, midprice_k, spread_k, **WMP 微价格** (Stoikov 2014): $\frac{a \cdot bs + b \cdot as}{bs + as}$, bid_diff/ask_diff 档内梯度 snapshot 表示, F2-F6 衍生底座
- ▶ **F2 多尺度 OFI** (0 raw + 50 派生, gain 5.5%)
MLOFI (Cont 2014, 多档 10×3 W): $e_t^{(k)} = \mathbf{1}_{b\uparrow} bs - \mathbf{1}_{b\downarrow} bs^- + \dots$, 窗口求和, $W \in \{5, 20, 60\}$
EWMA-OFI 多 $\alpha \in \{0.05, 0.1, 0.3, 0.5\}$; **Kyle** λ rolling & 反
$$\text{Kyle} = \frac{\Delta \text{amt}}{\sqrt[3]{|\Delta \text{amt}| \sigma + \epsilon}}$$
- ▶ **F3 订单流强度** (18 raw + 27 派生, **gain 35.1%**)
6 类事件 1/m/c b/a (limit/market/cancel × buy/sell) × intst/ind/acc 18 原始 + EWMA-intst 24 + cancel pressure 3 撮合层多空压力, **Top-4 全在此族**: $ma_intst=0.945, mb_intst=0.860, la/lb_intst=0.6$
- ▶ **F4 微结构波动** (2 raw + 27 派生, gain 7.5%)
 $\text{volume/amount_delta (sign-log1p 重尾压制), signed RV } \sum r^2, \text{bipower}$
 $\sum |r_i||r_{i+1}|$, **Roll spread** $2\sqrt{-\text{cov}(r_t, r_{t-1})}$, vol-burst (短窗口/长窗口 vol 比) 波动放大 → 方向转折
- ▶ **F5 窗口统计** (0 raw + 67 派生, gain 5.2%)
100-tick **z-score** $(x - \mu)/\sigma$, **dual-z** (两窗口比), **quantile rank** 窗口内分位, sym-agnostic 单族 gain 低但与所有族 $|\rho| \leq 0.07$, **OOD 稳健性 anchor**
- ▶ **F6 不对称性** (40 raw + 34 派生, gain 6.3%)
bid/ask rate L1-L10 (报价更新率), bsize/asize rate (挂单变化率), **GOFI** (Generalized OFI 含 cancel), EWMA residual (买卖侧不对称残差) 买卖侧异质性



F1+F3 = 75.5% gain (主力); **F5** 与全族近正交 ($|\rho| \leq 0.07$) = OOD 方差源去相关; **3 类预处理**: window-z (+22.88 PnL) / 镜像增强 (+2.41) / sign-log1p (重

三类关键预处理——window-z 单 trick 拉高 +22.88

window-z score

所有统计量在 100-tick 切片内自适应归一化

- ⇒ 跨 stock 分布差异被窗口吸收
- ⇒ 训练外股票也能 zero-shot

+22.88 PnL

买卖镜像数据增强

训练样本与 bid↔ask 互换 + 标签反转的镜像拼接

- ⇒ 训练集 $\times 2$
- ⇒ 强制方向对称先验

+2.41 PnL

稳健归一化 (sign-log1p)

amount_delta 量级 10^3-10^6 ，重尾压制：

$$v \mapsto \text{sign}(v) \log(1+|v|)$$

- ⇒ NN/LGB 梯度数值稳定
- ⇒ LGB 大幅受益, NN 中性

主题：在输入侧让模型“看不见”非平稳分布偏移——**范化性**的根本。

模型工程 (A)：NN 架构——纯 MLP 的设计启示

本任务的 4 个客观属性

- ① 数据集小 (5 stock × 120 day)
- ② 训练/测试股票可能切换，**难利用跨股票信息**
- ③ 评测时**只能用 100 ticks 窗口信息**
- ④ 因子已充分蒸馏潜在信息，**MLP 非线性已足够**

从而推断

- ① 复杂**时序**架构 (CNN/RNN/TCN) 用处小 (只 100 ticks，因子已聚合)
- ② 复杂**跨通道**架构 (Transformer) 发挥空间小 (跨 stock 信息难用)
- ③ 复杂架构容易**过拟合**小数据

⇒ 只用 4-layer MLP；实验也表明换更复杂架构都**没有更好**。

架构	参数量	Test PnL ($h=60$, V4)	备注
MLP (主线, 4-layer)	134k	+34.44 ± 1.39 (5 s)	表格类 [256/128/64]
AutoInt	1.12M	+32.98 (1 s)	表格类 feature attention
MLP-Mixer (4-layer)	2.08M	+30.18 (2 s)	表格类 ep 0 即过拟合
GatedMLP	274k	+27.56 ± 2.07 (5 s)	表格类 gate 无增益
ResMLP	1.15M	+26.72 ± 3.88 (5 s)	表格类高方差
FT-Transformer (flashattn)	16k	+24.18 ± 3.35 (2 s)	表格类 attn 无增益
TimeMixer	274k	+31.44 ± 1.47 (5 s)	时序类
ModernTCN	56k	+0.77 ± 0.84 (5 s)	时序类 conv 无法学
TimeKAN	29k	+0.04 ± 0.08 (5 s)	时序类 KAN 无法学

文献佐证：TLOB/MLPLOB (Zhang 2024) ——复杂模型在某些表格场景下并不显著优于 MLP；Scaling Law for TS Forecasting (Shi et al. NeurIPS 24') ——数据 & 回看长度限制 TS 模型上限。



模型工程 (B): GBDT 同族对比——相同 *setting* 下不同 *GBDT*

GBDT	Test PnL ($h=60$)	备注
LightGBM L2	+26.58 $\pm$ 0.96 (5 seeds)	359-d Feature, L2 回归 + class-balanced tree_method=gpu_hist, 同 setting, 与 LGB 持平 同 setting, 与 LGB 持平, 方差较大
XGBoost L2	+28.22 $\pm$ 0.66 (5 seeds)	
CatBoost L2	+26.67 $\pm$ 2.23 (5 seeds)	

相同 *walk-forward setting* + 同 359-d SchemeP feature + L2 target + 镜像增强 + window-z, 只换 GBDT 库;
实际尝试将 XGBoost 并入 50+50 集成, 公榜累计收益率**并无提升**, 故最终主线仍只保留 LightGBM。

观察: GBDT 三家基本差不多 ($LGB \approx XGB \approx CatBoost$), 库选择不是瓶颈。

训练核心：SPO+ 决策焦点学习——Phase 1 L2 预训练 → Phase 2 SPO+ finetune



两阶段训练流程

① Phase 1 —— L2 回归预训练

目标 $y = (\text{mp}_{t+60} - \text{mp}_t) / (\text{mp}_t + 1)$

② Phase 2 —— SPO+ joint finetune

warm-start, 全量数据 (train+val, 0-119) SPO+ 联合优化

SPO+ surrogate (Elmachtoub & Grigas 2022):

$$\ell_{\text{SPO}+} = \text{ReLU}(|2\hat{y} - y| - f) - z^*(y)(2\hat{y} - y) + f|z^*(y)|$$

两个好处

- ▶ (1) 对齐买卖 PnL
- ▶ (2) 全数据 Data scaling

+3.54 PnL

集成 & 执行: 50×50 simple-mean + ETUD 非对称阈值

50 NN + 50 LGB 异质集成

$50 = 5\text{HP} \times 10\text{seed}$; simple mean;

跨族 $w_{\text{NN}} : w_{\text{LGB}} = 1.0 : 1.5$

超参搜索 OOD 不一定靠谱: Val Test Gap

seed	lr / dropout / batch	val PnL	test PnL
1	10^{-4} / 0.05 / 2048	44.58	35.09
2	$3 \cdot 10^{-4}$ / 0.10 / 4096	39.07	36.94
3	10^{-3} / 0.15 / 8192	34.38	37.34
4	10^{-4} / 0.20 / 2048	34.52	37.80
5	$3 \cdot 10^{-4}$ / 0.05 / 4096	38.78	33.47

ETUD ——非对称执行阈值

$$\hat{a} = \begin{cases} +1 \text{ (买)}, & \hat{y} > +\theta_{\text{up}} \\ -1 \text{ (卖)}, & \hat{y} < -\theta_{\text{dn}} \\ 0, & \text{otherwise} \end{cases}$$

$$\theta_{\text{up}} = 3.00 \times 10^{-4}, \theta_{\text{dn}} = 2.16 \times 10^{-4}$$


集成规模 vs 公榜累计收益率

规模	HP $\times$ seed	公榜 PnL
5+5	1×5	+34.64
50+50	5×10	+35.64 (SOTA)
150+150	15×10	+34.59

$5 \rightarrow 50$ HP cycling 上榜 +1.00; 继续扩到 15 HP 反退 -1.05。

大消融 waterfall ——按领域上色：Feature → Ensemble & Execution

关键 trick 增益 waterfall —— 按领域上色：Feature → Ensemble & Execution



PnL 为本地测试集结果



Leaderboard —— 私榜 #1 ($h=60$) / $h=40$ #1

榜单	h	准确率	召回率	$F_{0.5}$	单次收益率	累计收益率 (评分)
公榜	60	0.3233	0.3177	0.3222	1.91×10^{-4}	35.64
私榜	60	0.3122	0.3390	0.3172	2.39×10^{-4}	41.61 (#1)
私榜	40	0.2712	0.4062	0.2905	1.94×10^{-4}	38.65 ($h=40$ #1)

研究针对 $h=60; h < 60: \theta(h') = \sqrt{h/60} \cdot \theta(60)$

第二部分：AI Agent 如何辅助量化比赛实战

我 + 我的 Agent 系统的开发节奏——6 天 / 100+ 轮实验 / 20 次公榜



辅助 Agent 将研究节奏从天加速到小时

AI Agent 研究系统：设计初衷 & 实现方案


设计初衷

- ▶ 正确性
- ▶ 高效性
- ▶ 可追溯性

实现方案

- ▶ Claude Code based agent — on server
- ▶ Manager-Worker 架构 — 单 Manager 易追踪管理、多 worker 可高效并行
- ▶ 周期唤醒消息 — Always On
- ▶ IM (飞书) 主交互界面 (IM first)
- ▶ 版本管理 & 记录 & 可视化:

GitHub Weights & Biases
vast.ai / HF



Agent 全天候跑在服务器上；飞书 IM 随时随地（手机 & 电脑）作为主交互界面；

GitHub/WandB 实验 log 作为辅助版本管理、实验理解和可视化工具；IDE (VS Code) 仅作代

分工：Agent 可以做 vs. 人需要做

► Agent 可以做

调研

paper search • brainstorm

实现 Coding

特征 • 训练 • ablation 脚本

给建议

validity check • bug review

◀ 人需要做

给定边界

sym-agnostic • 防数据污染 • OOD 警告

定义问题

决策问题 (非 3-class 分类)

拆分方向

因子 → 模型 → 集成 → 反思 → 正确性

搭建验证

V4 + LOSO • 平台公榜作 OOD 裁判

定方向

使用习惯变更：时间分配 & 人机交互

我的时间分配（打比赛）

阶段	想方向	调研 & 想 idea	实现 idea	反思
以前（前 Agent 时代）	1	4	4	1
现在（Agent 时代）	6	1	1	2

人类时间从“写代码”显著迁移到“定义问题 + 反思决策”。

人机交互

- ▶ 飞书 IM : VS Code = 8 : 2
- ▶ 目标定义: 方法分配: 编码 = 5 : 4 : 1
- ▶ Agent 承担: paper / brainstorm / coding / validity check / doc 生成

Takeaways: Agent 时代的量化（比赛）

量化侧

- ① Find the Right Axis to Scale
- ② Ask the Right Question
- ③ Ensure Right Verifications

Agent 侧

- ① 正确性
- ② 高效性
- ③ 可追溯性

感谢厦门大学、AITOPIA、组委会、 评委和老师们、所有同学们！



代码 (GitHub)

[https:](https://github.com/JingzheShi/liangwenbei)

[//github.com/JingzheShi/liangwenbei](https://github.com/JingzheShi/liangwenbei)



个人主页 (中文)

[https:](https://jingzheshi.github.io/index_cn.html)

[//jingzheshi.github.io/index_cn.html](https://jingzheshi.github.io/index_cn.html)



Personal Page (Eng)

<https://jingzheshi.github.io/>