

面向 PnL 目标的 LOB 中间价方向预测

Δmid 回归 + SPO+ 决策焦点学习 + 50×50 异质集成

史景喆（清华）

公榜 $-6.65 \rightarrow +35.64$ （baseline 之上增益 $+42.29$ ）

公榜 #1 | 私榜 #1 ($h=60$) | $h=40$ 私榜亦第一

第二届“良文杯”统计建模与 AI 预测挑战赛·决赛汇报

Problem 与评分——带交易成本的「期望收益预测」题

数据

- ▶ 5 只匿名 A 股 × 120 交易日 × 4002 ticks (3 秒/tick)
- ▶ 154 维原始字段: OHLC / **10 档 LOB** / **6 类订单流** (intst, ind, acc) / 衍生 spread & imbalance
- ▶ 1200 parquet, ~474 MB; 8 文件涨停日深档 ask 含少量 NaN (pipeline isfinite 兜底)

评分


- ▶ 动作 $\hat{a} \in \{0, 1, 2\}$, 仅买/卖扣 $\sim 0.02\%$ 双边手续费
- ▶ 总分 $\text{Score} = \max_{h \in \{5, 10, 20, 40, 60\}} \sum_i \text{pnl}_i^{(h)}$
- ▶ **本文以 $h=60$ 为主线**

评测端 3 条硬约束 (违反 = 0 分)

- ❶ date 被置 0 — 不能当 feature
- ❷ 测试点顺序被打乱 — Predictor 无跨调用 state
- ❸ sym 0–4 可能含训练外股票 — 模型必须 **sym-agnostic**: 不用 sym embedding / per-sym 归一化 / per-sym 模型

这 3 条约束塑造了所有后续设计——特别是 *window-z* 归一化与 *simple-mean* 集成。

方案 Pipeline 一览



Data → 6 家族 Feature (359 维) → NN(MLP) + LGB(L2 回归) 异质 Model → Ensemble → Execution (ETUD 阈值学习) → Label

因子工程：六大家族——F1 + F3 合计占 LGB gain 75.5%

► F1 LOB 派生 (105 维, gain 40.4%)

10 档 bid/ask 价 + 量、OHLC、WMP 微价格、bid_diff/ask_diff; snapshot 表示, F2-F6 派生底座

► F2 多尺度 OFI (50 维, gain 5.5%)

MLOFI / EWMA-OFI 多 α / Kyle λ rolling $W=5/20/50/100$; 5-100 tick 多窗口订单流不平衡

► F3 订单流强度 (45 维, gain 35.1%)

6 类事件 lb/la/mb/ma/cb/ca $\times$ intst/ind/acc + EWMA + cancel; 撮合层多空压力, **Top-4 因子全在此族** (ma_intst gain 0.90 全特征第一)

► F4 微结构波动 (29 维, gain 7.5%)


signed RV / bipower / Roll spread / vol-burst + volume_delta; 波动放大 $\rightarrow$ 方向转折概率上升

► F5 窗口统计 (67 维, gain 5.2%)

100-tick z-score / dual-z / quantile rank; 单族贡献低, 与所有族 $|\rho| \leq 0.07$, **OOD 稳健性 anchor**

► F6 不对称性 (74 维, gain 6.3%)

bid/ask rate L1-L10 + bsize/asize rate + GOFI + EWMA residual; 买卖侧异质性



F1 + F3 = 75.5% gain 是预测主力; F5 与其他族近正交 ($|\rho| \leq 0.07$) $\Rightarrow$ **OOD 红利的“方差源去相关”通道。**

三类关键预处理——window-z 单 trick 拉高 +22.88

window-z score

所有统计量在 100-tick 切片内自适应归一化

- ⇒ 跨 stock 分布差异被窗口吸收
- ⇒ 训练外股票也能 zero-shot

+22.88 PnL
(单 trick 最大跃升)

买卖镜像数据增强

训练样本与 bid↔ask 互换 + 标签反转的镜像拼接

- ⇒ 训练集 $\times 2$
- ⇒ 强制方向**对称先验**

+2.41 PnL

稳健归一化 (sign-log1p)

amount_delta 量级 10^3-10^6 ，重尾压制：

$$v \mapsto \text{sign}(v) \log(1+|v|)$$

- ⇒ NN/LGB 梯度数值稳定
- ⇒ LGB 大幅受益, NN 中性

(与 F5/F6 一同贡献)

共同主题：在输入侧让模型“看不见”非平稳分布偏移，这是 OOD 上能稳的根本。

模型工程 (A)：NN 架构对比——为什么用 4-layer MLP，不用更复杂的

架构	参数量	Test PnL ($h=60$)	备注
MLP (主线)	134k	+34.44 $\pm$ 1.39 (5 seeds)	4-layer [256/128/64]
ResMLP	1.15M	+26.72 $\pm$ 3.96 (5 seeds)	加深 + residual, 高方差 (-7.7 PnL)
MLP-Mixer	2.08M	+30.18 (2 seeds, best_ep=0)	参数量大反而 in-sample 过拟合
FT-Transformer	–	OOM (batch 2048, 16 GiB)	359-token 全 attention 炸显存

观察

- ▶ 100-tick 时序信息已被 aggregate features 蒸馏 (intst/OFI/RV...) $\Rightarrow$ raw-tick conv/attention **in-sample 高, OOD 退**
- ▶ T184 TickTransformer / T185 hybrid CNN: V4 验证 MSE drop 0%, verdict architecture_doesn't_fit
- ▶ T172 GroupTransformer in-sample +149.91, 但训练含测试日期污染, **PM 主动未提交**

与近期文献一致

TLOB / MLPLOB (Zhang et al. 2024, *When MLPs beat the LOB Transformers*) ——当窗口时序已被 aggregate feature 蒸馏, **纯 MLP 在 LOB 上可达 SOTA。**

与我们观察一致 $\Rightarrow$ 最终冻结 **4-layer MLP + SPO+ DFL。**

模型工程 (B): GBDT 同族对比——为什么用 *LightGBM*, 不用 *XGBoost* / *CatBoost*

GBDT	Eval	结果	为什么没选
LightGBM (主线)	V4 walk-forward	+30.88 $\pm$ 1.09 (50 seed M7)	GPU 训快 $\sim 3.2\times$, L2 + 359 维 SchemeP
XGBoost L2 (T18)	LOSO 5-fold	ceiling $\approx +22$, parity LGB	同族无增益, 速度劣
CatBoost L2 5-seed (T17/T89)	LOSO-eq + 公榜	LOSO +40.13, NN-CB corr 0.77	与 NN 主线 高度共线 ; iter_016 公榜 -3.08

核心观察



- ▶ GBDT 同族都 **saturate 在 LightGBM L2 + 359 维 SchemeP 这个组合**
- ▶ CatBoost 看似强 (LOSO +40.13) 但 NN-CB corr 0.77, **加进 ensemble 反伤公榜** -3.08 (共线性, 无方差减少红利)
- ▶ XGBoost L2 与 LightGBM L2 持平, 但 `gpu_hist` 速度劣

为什么 L2 而不是 3-class CE?

回归保留**连续置信度**, ETUD 阈值层在执行侧二次决策;
分类把信息提前 collapse, 且费率门槛 f 不在 loss 里。

$\Rightarrow$ L2 + ETUD 是 **决策延后绑定**的最简实现。

训练核心：SPO+ 决策焦点学习——Phase 1 L2 预训练 → Phase 2 SPO+ finetune



两阶段训练流程

① Phase 1 —— L2 回归预训练

目标 $y = (\text{mp}_{t+60} - \text{mp}_t) / (\text{mp}_t + 1)$ ；光滑二次损失, 逼近真值, 提供良好初值

② Phase 2 —— SPO+ joint finetune

warm-start, 全量数据 (train+val, 0-119) L2 + SPO+ surrogate 联合优化

lr 3×10^{-5} , 11 ep, $\lambda=30$

SPO+ surrogate (Elmachtoub & Grigas 2022):

$$\ell_{\text{SPO+}} = \text{ReLU}(|2\hat{y} - y| - f) - z^*(y)(2\hat{y} - y) + f|z^*(y)|$$

两个好处

- ▶ (1) SPO+ —— 梯度从“预测准”对齐到“PnL 高”；让 NN 明确感知执行端的非对称买卖 reward（费率门槛 f 处的 kink）
- ▶ (2) 全量数据 finetune —— Phase 2 在 train+val 0-119 上做（与 M7 retrain 同思路），把验证集数据收回训练

+3.54 PnL（最大单一训练 trick 增益）

集成 & 执行: 50×50 simple-mean + ETUD 非对称阈值

Onepage Table 1 行 17→20 累计进展: (5+5) ensemble +37.12 → +ETUD 37.90 → +SPO+ 41.44
→ + 50×50 HP cycling 41.58 (SOTA)

50 NN + 50 LGB 异质集成

5 组 HP $\times$ 10 seed = 50 NN + 50 LGB

simple mean, 不学权重; 跨族权重 **NN : LGB = 1.0 : 1.5**

为什么?

- NN-NN avg $|\rho| = 0.93$, LGB-LGB 0.84
- 设计矩阵条件数 5.4×10^4 (病态共线)
- bounded NNLS 本地涨, 公榜 **-4.64**

OOD 上 simple mean 是稳健最优

ETUD ——非对称执行阈值


$$\hat{a} = \begin{cases} +1 \text{ (买)}, & \hat{y} > +\theta_{\text{up}} \\ -1 \text{ (卖)}, & \hat{y} < -\theta_{\text{dn}} \\ 0, & \text{otherwise} \end{cases}$$

$\theta_{\text{up}} = 3.00 \times 10^{-4}$, $\theta_{\text{dn}} = 2.16 \times 10^{-4}$
ratio 0.8 约束 2D DE 搜索, 验证集冻结
不对称匹配训练样本正向漂移
⇒ 避免 wide-DE 在 OOF 上过拟合

决策参数不在 OOF 上学权重, 只在执行侧用 1 个二维阈值搜——OOD 上“简单 = 稳健”的延伸。

大消融 waterfall ——按领域上色：Feature → Ensemble & Execution

关键 trick 增益 waterfall —— 按领域上色：Feature → Ensemble & Execution



3 个高 ROI trick：
window-z +22.88 (Feature/OOD) • **F6 不对称性 +4.64** (Feature) • **SPO+ DFL +3.54** (Ensemble&Exec)

Leaderboard —— 公榜 #1 / 私榜 #1 / $h=40$ 私榜亦第一

榜单	h	准确率	召回率	$F_{0.5}$	单次收益率	累计收益率 (评分)
公榜	60	0.3233	0.3177	0.3222	1.91×10^{-4}	35.64 (#1)
私榜	60	0.3122	0.3390	0.3172	2.39×10^{-4}	41.61 (#1)
私榜	40	0.2712	0.4062	0.2905	1.94×10^{-4}	38.65 ($h=40$ 第一)

- ▶ 本文研究主线 $h=60$ ，模型/损失/特征/阈值**全部围绕 $h=60$ 优化**
- ▶ $h < 60$ 不重新训练、不重新调参，只按 $\sqrt{h/60}$ 简单缩放阈值
- ▶ 即便如此 $h=40$ 仍取该 horizon 第一 (+38.65)

准确率/召回率/ $F_{0.5}$ 针对涨/跌出手类 ($label \in \{0, 2\}$)，
“不出手”不计；评分 = 累计收益率。

Takeaways —— 5 条对未来 LOB 实盘有迁移价值的经验

- ① **sym-agnostic 是硬约束，不是“建议”** — 任何 sym embedding / per-sym 归一化 / per-sym 模型都会被评测端打散。**在输入侧 (window-z) 解决，比在模型侧绕路简单 10 倍。**
- ② **决策焦点学习给 +3.54 PnL** — 把 L2 回归改 SPO+ 决策焦点 surrogate，让梯度真正对齐执行端的离散动作期望收益。**评分函数本身就是 loss，最好的 loss 是 surrogate of scoring。**
- ③ **OOD 上 simple mean > learned weights** — 基模型平均 corr 0.84/0.93、设计矩阵病态共线下，bounded NNLS 本地涨而公榜 -4.64。**决策参数不要在 OOF 上学。**
- ④ **F1 + F3 = 75.5% 的 LGB gain** — LOB 派生 + 订单流强度是绝大多数 alpha 的载体；F2/F4/F5/F6 是**方差源去相关而非均值源。**
- ⑤ **窗口 + 镜像 + 稳健归一化** — 三个看似“小”的预处理一起，把 NN 从 +0.52 抬到 +34；**特征工程的复利远超模型架构选择。**

谢谢评委 & 良文杯组委会

累计收益率 (公榜): **+35.64 (#1)**

累计收益率 (私榜): **+41.61 (#1)**

起点 baseline: $-6.65 \Rightarrow$ 净增益 **+42.29**

史景喆 (清华大学)

代码开源: github.com/JingzheShi/liangwenbei