

# 面向 PnL 目标的 LOB 中间价方向预测

$\Delta\text{mid}$  回归 + SPO+ 决策焦点学习 +  $50 \times 50$  异质集成

---

史景喆 清华大学

队伍随机码 792 | 队伍：超级回天什么时候上映

公榜  $-6.65 \rightarrow +35.64$  (baseline 之上增益  $+42.29$ )

公榜 #1 | 私榜 #1 ( $h=60$ ) |  $h=40$  私榜亦第一

第二届“良文杯”统计建模与 AI 预测挑战赛·决赛汇报

# Problem 与评分——这是一道带交易成本的「期望收益预测」题

## 数据

- ▶ 5 只匿名 A 股 × 120 交易日 × 4002 ticks (3 秒/tick)
- ▶ 154 维原始字段: OHLC / **10 档 LOB** / **6 类订单流** (intst, ind, acc) / 衍生 spread & imbalance
- ▶ 1200 parquet, ~474 MB; 8 文件涨停日深档 ask 含少量 NaN (pipeline isfinite 兜底)

## 评分


- ▶ 动作  $\hat{a} \in \{0, 1, 2\}$ , 仅买/卖扣  $\sim 0.02\%$  双边手续费
- ▶ 总分  $\text{Score} = \max_{h \in \{5, 10, 20, 40, 60\}} \sum_i \text{pnl}_i^{(h)}$
- ▶ **本文以  $h=60$  为主线**

## 评测端 3 条硬约束 (违反 = 0 分)

- ① date 被置 0 — 不能当 feature
- ② 测试点顺序被打乱 — Predictor 无跨调用 state
- ③ sym 0–4 可能含训练外股票 — 模型必须 sym-agnostic: 不用 sym embedding / per-sym 归一化 / per-sym 模型


这 3 条约束塑造了所有后续设计——特别是 *window-z* 归一化与 *simple-mean* 集成。

# 方案 Pipeline 一览



Data → 6 家族 Feature (359 维) → NN(MLP) + LGB(L2 回归) 异质 Model → Ensemble → Execution (ETUD 阈值学习) → Label

# 因子工程：六大家族——F1 + F3 占 LGB gain 75.5%



- **F1 LOB 派生 (40.4% gain)**: 10 档报价/挂单量 + WMP + spread
- **F3 订单流强度 (35.1% gain)**: ma/mb/la/lb\_intst + EWMA

Top-10 因子全在 F1+F3; F5 与其它族  $|\rho| \leq 0.07$ , 正交补强。

# 三类关键预处理——window-z 单 trick 拉高 +22.88

## window-z score

所有统计量在 100-tick 切片内自适应归一化

- ⇒ 跨 stock 分布差异被窗口吸收
- ⇒ 训练外股票也能 zero-shot

+22.88 PnL  
(单 trick 最大跃升)

## 买卖镜像数据增强

训练样本与 bid↔ask 互换 + 标签反转的镜像拼接

- ⇒ 训练集  $\times 2$
- ⇒ 强制方向**对称先验**

+2.41 PnL

## 稳健归一化 (sign-log1p)

amount\_delta 量级  $10^3-10^6$ ，重尾压制：

$$v \mapsto \text{sign}(v) \log(1+|v|)$$

- ⇒ NN/LGB 梯度数值稳定
- ⇒ LGB 大幅受益, NN 中性

(与 F5/F6 一同贡献)

共同主题：在输入侧让模型“看不见”非平稳分布偏移，这是 OOD 上能稳的根本。

# 模型工程：异质 NN + LGB ——故意不用 RNN/Transformer/CNN

## NN : 4-layer MLP

[359  $\rightarrow$  256  $\rightarrow$  128  $\rightarrow$  64  $\rightarrow$  1] ( $\sim$ 120k 参数)

LayerNorm + GELU + Dropout

**LayerNorm 走样本级**  $\Rightarrow$  避免 batch 内污染

为什么不用更复杂架构？

window-z + 6 家族派生已经把 100-tick 时序信息蒸馏成静态因子，

RNN/Transformer/CNN 容易 in-sample 膨胀，OOD 反而退化。

## LGB : L2 $\Delta$ mid 回归

objective = regression\_l2

目标  $y = (\text{mp}_{t+60} - \text{mp}_t) / (\text{mp}_t + 1)$

**class-balanced 样本权重** ( $h=60$  三类频率倒数)

$\Rightarrow$  稀疏涨/跌样本得到更高梯度



为什么 L2 而不是 3-class CE?

回归保留连续置信度，

ETUD 阈值层可在执行侧二次决策；分类把信息提前 collapse。

族内 simple mean，跨族固定权重 **LGB : NN = 1.5 : 1** (GBDT 在表格数据上略强  $\Rightarrow$  略重)

# 训练核心：SPO+ 决策焦点学习——把梯度对齐离散动作的期望收益



## 核心问题：

L2 回归追真值，但评分只关心动作  $\hat{a}$  是否越过费率门槛  $f$ 。

**SPO+ surrogate (Elmachtoub & Grigas 2022):**

$$\ell_{\text{SPO+}} = \text{ReLU}(|2\hat{y} - y| - f) - \hat{z}(y)(2\hat{y} - y) + f\hat{z}(y)$$

$$L = (\hat{y} - y)^2 + \lambda \ell_{\text{SPO+}}, \lambda = 30$$

## 两阶段：

- Phase 1 —pure L2 回归预训练
- Phase 2 —warm-start 联合 L2 + SPO+ 微调 (lr  $3 \times 10^{-5}$ , 11 ep)

+3.54 **PnL** (最大单一训练 trick 增益)

# 集成 & 执行: $50 \times 50$ simple-mean + ETUD 非对称阈值

## 50 NN + 50 LGB 异质集成

5 组  $HP \times 10$  seed = 50 NN + 50 LGB

simple mean, 不学权重

为什么?

- NN-NN avg  $|\rho| = 0.93$ , LGB-LGB 0.84
- 设计矩阵条件数  $5.4 \times 10^4$  (病态共线)
- bounded NNLS 本地涨, 公榜  $-4.64$

OOD 上 simple mean 是稳健最优

## ETUD ——非对称执行阈值

$$\hat{a} = \begin{cases} +1 \text{ (买)}, & \hat{y} > +\theta_{\text{up}} \\ -1 \text{ (卖)}, & \hat{y} < -\theta_{\text{dn}} \\ 0, & \text{otherwise} \end{cases}$$

$$\begin{aligned} \theta_{\text{up}} &= 3.00 \times 10^{-4} \\ \theta_{\text{dn}} &= 2.16 \times 10^{-4} \end{aligned}$$


由验证集 2D DE 搜出后冻结  
不对称匹配训练样本正向漂移

决策参数不在 OOF 上学权重, 只在执行侧用 1 个二维阈值搜——这是 OOD 上“简单 = 稳健”的延伸。



# 大消融 waterfall —— 从 +0.52 到 +41.58 的 9 步关键跳跃

关键 trick 增益 waterfall —— 起点 NN raw+L2 (0.52) → 集成最终 41.58



3 个高 ROI trick : **window-z +22.88** (输入侧 OOD) • **SPO+ DFL +3.54** (训练侧决策对齐) • **F6 不对称性 +4.64** (因子)

# Leaderboard —— 公榜 #1 / 私榜 #1 / $h=40$ 私榜亦第一

| 榜单 | $h$ | 准确率    | 召回率    | $F_{0.5}$ | 单次收益率                 | 累计收益率 (评分)                          |
|----|-----|--------|--------|-----------|-----------------------|-------------------------------------|
| 公榜 | 60  | 0.3233 | 0.3177 | 0.3222    | $1.91 \times 10^{-4}$ | <b>35.64 (#1)</b>                   |
| 私榜 | 60  | 0.3122 | 0.3390 | 0.3172    | $2.39 \times 10^{-4}$ | <b>41.61 (#1)</b>                   |
| 私榜 | 40  | 0.2712 | 0.4062 | 0.2905    | $1.94 \times 10^{-4}$ | <b>38.65 (<math>h=40</math> 第一)</b> |

- ▶ 本文研究主线  $h=60$ ，模型/损失/特征/阈值**全部围绕**  
 $h=60$  **优化**
  - ▶  $h < 60$  不重新训练、不重新调参，只按  $\sqrt{h/60}$  简单缩放阈值
  - ▶ 即便如此  $h=40$  仍取该 horizon 第一 (+38.65)
- 准确率/召回率/ $F_{0.5}$  针对涨/跌出手类  
( $label \in \{0, 2\}$ )，  
“不出手”不计；评分 = 累计收益率。

## Takeaways —— 5 条对未来 LOB 实盘有迁移价值的经验

- ① **sym-agnostic 是硬约束，不是“建议”** — 任何 sym embedding / per-sym 归一化 / per-sym 模型都会被评测端打散。**在输入侧 (window-z) 解决，比在模型侧绕路简单 10 倍。**
- ② **决策焦点学习给 +3.54 PnL** — 把 L2 回归改 SPO+ 决策焦点 surrogate，让梯度真正对齐执行端的离散动作期望收益。**评分函数本身就是 loss，最好的 loss 是 surrogate of scoring。**
- ③ **OOD 上 simple mean > learned weights** — 基模型平均 corr 0.84/0.93、设计矩阵病态共线下，bounded NNLS 本地涨而公榜 -4.64。**决策参数不要在 OOF 上学。**
- ④ **F1 + F3 = 75.5% 的 LGB gain** — LOB 派生 + 订单流强度是绝大多数 alpha 的载体；F2/F4/F5/F6 是**方差源去相关而非均值源。**
- ⑤ **窗口 + 镜像 + 稳健归一化** — 三个看似“小”的预处理一起，把 NN 从 +0.52 抬到 +34；**特征工程的复利远超模型架构选择。**

# 谢谢评委 & 良文杯组委会

---

累计收益率 (公榜): **+35.64 (#1)**

累计收益率 (私榜): **+41.61 (#1)**

起点 baseline:  $-6.65 \Rightarrow$  净增益 **+42.29**

队伍 **792** • 超级回天什么时候上映 • 史景喆 (清华大学)

代码开源: [github.com/JingzheShi/liangwenbei](https://github.com/JingzheShi/liangwenbei)