

答辩小抄: Feature 工程 Q&A 速查

用于答辩时被老师追问因子细节、跨股 / 跨日泛化、KS-drop-11 的现场速查。来源: factor_families_report_v4.pdf §4 / AN-SWERS_P3_FEATURES.md §6 / onepage_v2/sweep_5seed_summary.json / ablation_runs/feat_family_progressive/build_parallel / factor_per_feature_audit/MASTER_summary.md / h_horizon_study/REPORT.md (5 horizon × 5 seed 实测)。

§0 符号与缩写速查表 (老师翻这里)

§0.1 英文缩写

缩写	英文全称	中文
LOB	Limit Order Book	限价订单簿
OFI	Order Flow Imbalance	订单流不平衡
MLOFI	Multi-Level Order Flow Imbalance	多档订单流不平衡
GOFI	Generalized Order Flow Imbalance	广义订单流不平衡
EWMA	Exponentially Weighted Moving Average	指数加权移动平均
WMP	Weighted Mid-Price (Stoikov 2014)	加权微价格
RV	Realized Volatility	实现波动率
BV	Bipower Variation	二次幂变差
Roll	Roll (1984) effective spread	Roll 有效价差
Kyle λ	Kyle (1985) lambda	Kyle 价格冲击系数
KyleInv	Kyle inverse impact	Kyle 反向冲击系数
BNS	Barndorff-Nielsen-Shephard	BNS 跳跃份额估计
KS	Kolmogorov-Smirnov test	K-S 分布检验
PSI	Population Stability Index	群体稳定性指数
SPO+	Smart Predict-then-Optimize Plus	决策焦点损失 (增强版)
DFL	Decision-Focused Learning	决策焦点学习
ETUD	Execution Threshold Up / Down	非对称执行阈值
EV	Expected Value	期望收益
NN	Neural Network	神经网络 (此处特指 MLP)
MLP	Multi-Layer Perceptron	多层感知机
LGB	LightGBM	微软梯度提升决策树
HFT	High-Frequency Trading	高频交易
OOD	Out-of-Distribution	分布外
LOSO	Leave-One-Sym-Out	留一只股票出来 (交叉验证)
IIR	Infinite Impulse Response	无限脉冲响应 (滤波器)
NNLS	Non-Negative Least Squares	非负最小二乘
HL	Half-Life	半衰期
IQR	Interquartile Range	四分位距
OHLC	Open-High-Low-Close	开高低收四价
DeepLOB	Deep LOB CNN	主办方 baseline 模型
CNN	Convolutional Neural Network	卷积神经网络
RNN	Recurrent Neural Network	循环神经网络
TCN	Temporal Convolutional Network	时序卷积网络
KAN	Kolmogorov-Arnold Network	KA 网络
PnL	Profit and Loss	盈亏 (评分指标)
intst	intensity	订单事件到达强度 (换手率% 单位)
ind	indicator	订单事件 0/1 指示 (过去 1 tick 均值 > 过去 60 tick 均值 → 1)
acc	acceleration	订单事件强度的单 tick 变化率 (“到达加速度”)
cumspread	Cumulative Spread	累积价差 (10 档价差求和)
cancel_imb	Cancel Imbalance	撤单不平衡
dualz	Dual-window z-score	双窗 z-score (短窗 z - 长窗 z)
qrank	Quantile Rank	分位排名
adapt_mom	Adaptive Momentum	自适应动量 (方向 × 强度)
spread_reg	Spread Regime	价差体制 (鲁棒 z-score on spread)
trade_pers	Trade Persistence	交易持久性 (相邻方向自相关)
mid_ewma_resid	Midprice EWMA Residual	中间价 EWMA 残差
signed_rv	Signed Realized Volatility	方向化实现波动率
signed_bv	Signed Bipower Variation	方向化二次幂变差
rskew	Return Skewness	log-return 偏度
vol_burst	Volume Burst	成交量突发倍数
amt_burst	Amount Burst	成交金额突发倍数
rv_ratio	RV Ratio	短/长窗 RV 比 (活跃度变化率)
jshare	Jump Share	跳跃份额
roll_eff_spr_ratio	Roll Effective Spread Ratio	Roll 有效价差比
ofi_tox	OFI Toxicity	有毒订单流比例
ewma_ofi	EWMA-OFI	指数加权 OFI
liq_asym	Liquidity Asymmetry	流动性不对称
wmp_lvl	WMP Level-k	第 k 档加权微价格
bid_diff / ask_diff	Bid/Ask Level Spread	同侧相邻档位价差
bid_rate / ask_rate	Bid/Ask Price Rate	第 k 档买/卖价滑动平均变化率 (主办方提供)
bsize_rate / asize_rate	Bid/Ask Size Rate	第 k 档买/卖挂量滑动平均变化率 (主办方提供)
gofi	Generalized OFI	广义订单流不平衡 (含同价挂量净变化)
mlofi	Multi-Level OFI	多档订单流不平衡
kyle_inv	KyleInv	Kyle 反向冲击系数
kyle_lam	Kyle λ	Kyle 价格冲击系数 (lambda)

§0.2 数学符号

符号	定义
t	tick 索引 (每 3 秒一个 tick)
k	LOB 档位索引, $k \in \{1, 2, \dots, 10\}$
W	滑动窗口长度 (tick 数), 常用 $W \in \{5, 20, 50, 100\}$
h	预测视距 (horizon), 常用 $h \in \{10, 40, 60\}$ tick
α	EWMA 衰减系数, $\alpha \in \{0.05, 0.1, 0.3, 0.5\}$, 对应 $HL \approx 13 / 7 / 2 / 1$ ticks ($HL \approx \ln 2 / (-\ln(1 - \alpha))$)
$b_t^{(k)}$	bid_k: 第 k 档买盘报价 (在 tick t)
$a_t^{(k)}$	ask_k: 第 k 档卖盘报价
$bs_t^{(k)}$	bsize_k: 第 k 档买盘挂单量
$as_t^{(k)}$	asize_k: 第 k 档卖盘挂单量
mp_t	midprice: $(b_t^{(1)} + a_t^{(1)})/2$
Δmp_t	未来 h -tick 中间价变化: $mp_{t+h} - mp_t$ (回归目标的基础)
Δamt_t	amount_delta: 单 tick 成交金额变化
r_t	log-return: $\log(mp_t / mp_{t-1})$
$\mu_W(\cdot)$	长度 W 的滑窗均值
$\sigma_W(\cdot)$	长度 W 的滑窗标准差
$\mathbf{1}[\cdot]$	indicator 函数 (条件成立为 1, 否则为 0)
ε	分母小数兜底 (防除零, 典型 $\varepsilon = 10^{-8}$)
$\text{sgn}(\cdot)$	符号函数
$\text{cov}(\cdot, \cdot)$	协方差
$\text{var}(\cdot)$	方差
signed_dvol	方向化 dollar volume: $\text{sgn}(\Delta mp) \cdot \sqrt{ \Delta amt + \varepsilon}$
intst / ind / acc	6 类订单事件的「到达强度 / 0-1 指示 / 单 tick 变化率 (一阶)」
y_reg	回归目标 (Δmp 归一化后的标签)
y_cls	3 分类标签 (涨 = 2 / 平 = 1 / 跌 = 0)
$\hat{a}$	模型动作, $\hat{a} \in \{0, 1, 2\}$, 分别表示「卖 / 不动 / 买」
f	单边手续费率 (约 0.02%)

§0.3 概念一句话解释

- **OFI (Order Flow Imbalance, 订单流不平衡)**: 衡量 LOB 上 bid 侧净增量减去 ask 侧净增量。正值 = 买压增强 = 价格大概率上涨。
- **WMP (Weighted Mid-Price, 加权微价格)**: 用对侧 size 作权重去加权同侧价格。挂单少的那一侧权重重大, 反映「哪侧将先被耗尽」。
- **dualz (Dual-window z-score, 双窗 z-score)**: 短窗 z-score 减长窗 z-score, 消除全局基差只保留「短期相对长期的偏离」。
- **KS-drop (基于 KS 检验的特征剔除)**: 用 Kolmogorov-Smirnov 检验筛掉「单 sym 分布显著偏离全 sym 分布」的特征, 保证 sym-agnostic。

§0.4 论文引用

引用简称	完整引用	出处
Kercheval & Zhang 2015	Kercheval & Zhang, "Modelling high-frequency limit order book dynamics with support vector machines"	<i>Quantitative Finance</i> 15(8) —bid/ask rate、GOFI 等 LOB 衍生特征的来源
Cont, Kukanov & Stoikov 2014	Cont, Kukanov & Stoikov, "The Price Impact of Order Book Events"	<i>Journal of Financial Econometrics</i> —MLOFI 理论基础
Stoikov 2014	Stoikov, "The Micro-Price"	SSRN Working Paper —WMP 定义
Kyle 1985	Kyle, "Continuous Auctions and Insider Trading"	<i>Econometrica</i> —Kyle λ (价格冲击系数)
BNS / Barndorff-Nielsen & Shephard 2004	Barndorff-Nielsen & Shephard, "Power and Bipower Variation with Stochastic Volatility and Jumps"	<i>Journal of Financial Econometrics</i> —BV / jshare 跳跃检验
Roll 1984	Roll, "A Simple Implicit Measure of the Effective Bid-Ask Spread in an Efficient Market"	<i>Journal of Finance</i> —Roll 有效价差估计
Easley, López de Prado & O' Hara 2012	Easley, López de Prado & O' Hara, "Flow Toxicity and Liquidity in a High-Frequency World"	<i>Review of Financial Studies</i> —VPIN / OFI Toxicity 框架

Q1: 6 大家族的因子定义与计算公式

维度账: 154 raw + 216 derived = 370 维, **KS drop 11 → 359 喂模型**。SchemeP 的 F1-F6 是 370 维的完备分组 (互斥、并集 = 100%)。

F1 LOB (Limit Order Book, 限价订单簿) 派生: **94 raw + 11 派生 = 105 维·LGB gain 40.4%**

- **OHLC + 10 档报价 / 挂量 (44 raw)**: open / high / low / close、 $b_t^{(k)}$ 、 $a_t^{(k)}$ 、 $bs_t^{(k)}$ 、 $as_t^{(k)}$, $k = 1, \dots, 10$ 。
- **聚合 (8 raw)**:

- **avgbid** (Volume-Weighted Average Bid, 量权买价均值) = $\sum_k b_t^{(k)} \cdot bs_t^{(k)} / \sum_k bs_t^{(k)}$; **avgask** 同理 (卖侧)。
- **totalbsize** (Total Bid Depth, 总买盘深度 / 市场深度) = $\sum_{k=1}^{10} bs_t^{(k)}$; **totalasize** 同理。总挂单量越大 → 市场深度 (**market depth**) 越充裕 → 流动性越好。
- 主办方另给 4 个均值字段: **bid_mean** / **ask_mean** (10 档买/卖价等权均值 = $\frac{1}{10} \sum_k b_t^{(k)}$)、**bsize_mean** / **asize_mean** (10 档挂量等权均值)。与 avgbid/avgask 的区别: avgbid 是量权, bid_mean 是等权; ask_mean 存在约 3.9% NaN (深档偶无报价)。
- **midprice_k (10 row)**:

$$mp_t^{(k)} = \frac{b_t^{(k)} + a_t^{(k)}}{2}$$

- **spread_k (10 row)**: $spread_t^{(k)} = a_t^{(k)} - b_t^{(k)}$, 第 k 档买卖价差。衍生两个聚合指标:
 - **cumspread** (Cumulative Spread, 累积价差) = $\sum_{k=1}^{10} spread_t^{(k)} = 10(ask_mean_t - bid_mean_t)$ 。10 档价差累加, 刻画整个价格梯队总宽度 (spread 越宽 → 流动性越差)。
 - **imbalance** (Order-Book Imbalance, 订单簿不平衡; 源自 **Kercheval & Zhang 2015**) = $(totalbsize_t - totalasize_t) / (totalbsize_t + totalasize_t) \in (-1, +1)$ 。官方定义「十档累计买卖量差 (归一化)」: 正值 → 买压强 (价格倾向上行), 负值 → 卖压强。
- **bid_diff_k / ask_diff_k** (Bid/Ask Level Spread, 同侧相邻档位价差) (**20 row**): $b_t^{(k)} - b_t^{(k+1)}$ (买侧, $k = 1, \dots, 9$) 及 $a_t^{(k+1)} - a_t^{(k)}$ (卖侧)。**为什么有用**: 相邻档位差越小 → LOB 密度越高 → 大单冲击成本低; 价格梯队稀疏 → 流动性脆弱。深档 ask_diff8-10 因涨跌停日 ask 侧无报价存在 NaN (最高 $\approx 16.86\%$); bid 侧 NaN = 0%。
- **WMP** (Weighted Mid-Price, 加权微价格; Stoikov 2014, “The Micro-Price”) 派生 **11 维 (wmp_lvl1-10 + wmp_balance_12)**:

$$wmp_lvl_t^{(k)} = \frac{a_t^{(k)} \cdot bs_t^{(k)} + b_t^{(k)} \cdot as_t^{(k)}}{bs_t^{(k)} + as_t^{(k)} + \varepsilon}$$

重点: ask 价权 bs, bid 价权 as——挂单少的那一侧权重更大 (短缺侧把 mid 拉向它), 符合「哪边将耗尽就先走哪边」的微观结构直觉。另加 1 个 **wmp_balance_12** (WMP Level Balance, WMP 层间漂移) = $wmp_lvl_t^{(1)} - wmp_lvl_t^{(2)}$ 。正值 (L1 WMP > L2 WMP) → 短期下行压力: L1 ask 侧挂单将先被耗尽, 价格向 L2 下移。

F1 NaN 摘要: 94 raw 字段 (bid/ask/bsize/asize, OHLC、avgbid/totalbsize/bid_mean 等) 公式层无兜底, NN 路径走 nanmean/nanstd → nan_to_num(0) → clip(± 10) 三层; LGB 完全不动 (内置 missing routing)。深档 (**ask8-10 / asize8-10 / spread8-10 / ask_diff8-10**) 在涨跌停日 ask 侧无报价, 实测 train NaN $\approx 12.4-16.86\%$ (ask10/asize10 最高); 其余 raw $\approx 0\%$ 。11 个 WMP 派生已在公式层用 np.where(isfinite, x, 0) 兜底, 实测 NaN = 0%。

F2 多尺度 OFI (Order Flow Imbalance, 订单流不平衡): 0 raw + 50 派生·gain 5.5%
100% 派生、家族内 $|r| = 0.33$ 全场最高 (强冗余 → importance 被稀释)。

「多尺度」澄清: 这里「多尺度」不是固定术语, 而是指 OFI 系列指标在多个时间窗口 $W \in \{5, 20, 60\}$ 上同时计算, 覆盖短中期不同时间尺度的订单流信息。

- **MLOFI** (Multi-Level Order Flow Imbalance, 多档订单流不平衡; **Cont, Kukanov & Stoikov 2014, “The Price Impact of Order Book Events”, Journal of Financial Econometrics**) 30 维: $W \in \{5, 20, 60\} \times k \in \{1, \dots, 10\}$ 。核心单 tick 增量 $e_t^{(k)}$:

$$\begin{aligned} e_t^{(k)} = & \mathbf{1}[b_t^{(k)} \geq b_{t-1}^{(k)}] \cdot bs_t^{(k)} \\ & - \mathbf{1}[b_t^{(k)} \leq b_{t-1}^{(k)}] \cdot bs_{t-1}^{(k)} \\ & - \mathbf{1}[a_t^{(k)} \leq a_{t-1}^{(k)}] \cdot as_t^{(k)} \\ & + \mathbf{1}[a_t^{(k)} \geq a_{t-1}^{(k)}] \cdot as_{t-1}^{(k)} \end{aligned}$$

$$MLOFI_{t,W}^{(k)} = \sum_{s=t-W+1}^t e_s^{(k)}$$

直觉: bid 上行 (或不变) 贡献 $+bs_t$; bid 下行扣前一档 bs_{t-1} (即被吃单 / 撤单消失的挂量), 左右对称构成净 bid pressure。

- **EWMA-OFI** (Exponentially Weighted Moving Average of OFI, 指数加权 OFI) 12 维: $\alpha \in \{0.05, 0.1, 0.3, 0.5\} \times k \in \{1, 5, 10\}$:

$$\text{EWMA_OFI}_t^{(\alpha,k)} = \alpha \cdot e_t^{(k)} + (1 - \alpha) \cdot \text{EWMA_OFI}_{t-1}^{(\alpha,k)}$$

为什么比固定累加窗口好：(i) 平滑（减少单 tick 极端值影响）；(ii) 自动指数衰减历史，近期权重高、久远权重低，无需指定截断 W ；(iii) 无边界效应（不存在窗口截断造成的跳变）。- **KyleInv** (Kyle Inverse Impact, Kyle 反向冲击系数) **2 维**, $W \in \{50, 100\}$:

$$\text{KyleInv}_{t,W} = \frac{\Delta amt_t}{\sqrt[3]{|\Delta amt_t|} \cdot \sigma_W(r) + \varepsilon}$$

分子 Δamt_t : 单 tick 成交金额变化（带方向，正 = 净买入）。分母 $\sqrt[3]{|\Delta amt_t|} \cdot \sigma_W(r)$: 「活跃度 × 波动」的量纲归一化因子。物理含义：高波动期 ($\sigma_W(r)$ 大) 下单位金额能解释的方向变化弱 → 信号强度自适应缩小，避免高波动期被随机大额成交误导； $\sqrt[3]{\cdot}$ 比 $\sqrt{\cdot}$ 对大额 Δamt 压缩更激进，跨 sym 量纲更稳。

- **Kyle λ** (Kyle's Lambda, Kyle 价格冲击系数; **Kyle 1985, "Continuous Auctions and Insider Trading", Econometrica**) **2 维**, $W \in \{50, 100\}$:

$$\lambda_{t,W} = \frac{\text{cov}_W(\text{signed_dvol}, \Delta mp)}{\text{var}_W(\text{signed_dvol}) + \varepsilon}$$

分子 $\text{cov}_W(\text{signed_dvol}, \Delta mp)$: 方向化 dollar volume (= $\text{sgn}(\Delta mp) \cdot \sqrt{|\Delta amt| + \varepsilon}$) 与未来 mid 变化的协方差；分子大 → 资金流确实能推动价格。分母: signed_dvol 自身方差（标准化系数）。整族 **KS drop** 原因：不同股票的资金—价格弹性量纲和量级根本不同（ETF vs 主板各异），训练 sym 上估计的 λ 分布与 OOD sym 强烈偏移（见 Q3）。

- **OFI Toxicity** (有毒订单流比例；基于 **Easley, López de Prado & O' Hara 2012, "Flow Toxicity and Liquidity in a High-Frequency World", Review of Financial Studies** VPIN 框架) **4 维**, $k \in \{1, 5\} \times W \in \{20, 50\}$:

$$\text{ofi_tox}_t^{(k,W)} = \frac{1}{W} \sum_{s=t-W+1}^t \mathbf{1}[\text{sgn}(e_s^{(k)}) \neq \text{sgn}(\Delta mp_s)]$$

即窗口内「OFI 方向与价格变化方向不一致」的占比。高 **toxicity** → 订单流被信息驱动（知情者 / **HFT 套利**）→ 单向价格冲击，普通挂单无法对冲。

F2 NaN 摘要: 100% 派生，公式层全部含 +ε 防除零 + np.where(isfinite, x, 0) 兜底；NN 路径 nanmean/nanstd → nan_to_num → clip(±10)；LGB 不动（实际无 NaN）；实测所有 **F2 特征 NaN = 0%**。

F3 订单流强度: 18 raw + 27 派生 = 45 维·gain 35.1% —Top-4 全在此

主办方直接给的 6 类订单事件 × 3 变体: limit / market / cancel × buy / sell × intst / ind / acc。

6 类事件命名对照:

缩写	英文全称	中文
lb	limit-bid	限价买
la	limit-ask	限价卖
mb	market-bid	市价买
ma	market-ask	市价卖
cb	cancel-bid	撤单买
ca	cancel-ask	撤单卖

- **intst** (intensity, 订单事件到达强度；官方: 「从上个 tick 到当前 tick 的平均到达强度，量已转化为换手率%」) **6 raw**。模型 **Top-4 全在此** (主要靠 intst): ma_intst 0.945 (市价卖)、mb_intst 0.860 (市价买)、la_intst 0.65 (限价卖)、lb_intst 0.567 (限价买)。
- **ind** (indicator, 订单事件 0/1 指示；官方: 「过去 1 tick 平均强度 > 过去 60 tick 平均强度 → 1, 否则 0」) **6 raw**: 鲁棒二值兜底，抗量纲差异，树模型直接可用。
- **acc** (acceleration, 订单事件强度变化率；官方: 「从上个 tick 到当前 tick 的到达强度变化率，可理解为到达的加速度」) **6 raw**: 注意: acc 是「上个 tick 到当前 tick 的一阶变化率」而非二阶差分。6 维 gain 全部 < 0.05, 是死特征但保留 (drop 有风险, 不如让树模型自行忽略)。
- **EWMA-intst (24 派生)**: 6 类 × 4 个 α (IIR, Infinite Impulse Response 无限脉冲响应 滤波器):

$$\tilde{x}_t^{(\alpha)} = \alpha \cdot x_t + (1 - \alpha) \cdot \tilde{x}_{t-1}^{(\alpha)}$$

- **cancel_imb** (Cancel Imbalance, 撤单不平衡) **3 派生**, $W \in \{20, 50, 100\}$:

$$\text{cancel_imb}_{t,W} = \frac{\sum_{s=t-W+1}^t cb_s^{\text{intst}}}{\sum_{s=t-W+1}^t (lb_s^{\text{intst}} + mb_s^{\text{intst}} + cb_s^{\text{intst}}) + \varepsilon} - \frac{\sum_{s=t-W+1}^t ca_s^{\text{intst}}}{\sum_{s=t-W+1}^t (la_s^{\text{intst}} + ma_s^{\text{intst}} + ca_s^{\text{intst}}) + \varepsilon}$$

公式中所有变量为 **intst** (到达强度) 序列的窗口 W 内累加。正值 $\rightarrow$ 买侧撤单比例高于卖侧 $\rightarrow$ 买盘在收缩 $\rightarrow$ 潜在下行压力; 分母含 $\text{clip}(-1, 1)$ 兜底。

F3 NaN 摘要: 18 raw (intst/ind/acc $\times 6$) 公式层无兜底, NN 路径走 wz 三层或 $\text{nan_to_num}(0)$; LGB 不动。实测 NaN $\approx 0\%$ (主办方 cache 保证 finite)。24 个 EWMA-intst 派生含 $\text{np.where}(\text{isfinite}, x, 0)$ 兜底; 3 个 cancel_imb 含 $\text{denom} + \text{EPS} + \text{clip}(-1, 1)$ 兜底; 实测 NaN = 0%。

F4 微结构波动: 2 raw + 27 派生 = 29 维·gain 7.5%

- **volume_delta** (Volume Delta, 成交量变化) / **amount_delta** (Amount Delta, 成交金额变化) (**2 raw**): 均是 t 与 $t-1$ 之间的单 **tick** 差, 不是窗口累计。注: amount_delta 是唯一未归一化字段 (单位: 元, 量级 $10^3 \sim 10^6$), 需 sign-log1p 处理。
- **rv_W** (RV, **Realized Volatility** 实现波动率) **4 维**:

$$\text{RV}_{t,W} = \sum_{s=t-W+1}^t r_s^2, \quad W \in \{5, 10, 20, 50\}$$

- **signed_rv** (Signed Realized Volatility, 方向化实现波动率) **3 维**, $W \in \{20, 50, 100\}$, $\in [-1, 1]$:

$$\text{signed_rv}_{t,W} = \frac{\text{RV}_W^+ - \text{RV}_W^-}{\text{RV}_W^+ + \text{RV}_W^- + \varepsilon}$$

其中:

$$\text{RV}_W^+ = \sum_{s=t-W+1}^t r_s^2 \cdot \mathbf{1}[r_s > 0], \quad \text{RV}_W^- = \sum_{s=t-W+1}^t r_s^2 \cdot \mathbf{1}[r_s < 0]$$

signed_rv = +1 $\rightarrow$ 波动全由上涨贡献 (涨主导), -1 $\rightarrow$ 全由下跌贡献, 0 $\rightarrow$ 涨跌对称。

- **rskew** (Return Skewness, log-return 偏度) **3 维**, $W \in \{20, 50, 100\}$:

$$\text{rskew}_W = \text{clip}\left(\frac{m_3(r)}{\sigma_W(r)^3 + \varepsilon}, -10, +10\right)$$

$m_3(r) = \frac{1}{W} \sum_s (r_s - \bar{r})^3$ 为三阶中心矩。正偏 (右偏) $\rightarrow$ 大涨概率大于大跌; 负偏 $\rightarrow$ 尾部下行风险更重。-

signed_bv (Signed Bipower Variation, 方向化二次幂变差; **BNS 2004**) **3 维**, $W \in \{20, 50, 100\}$:

$$\text{signed_bv}_{t,W} = \text{clip}\left(\frac{\frac{\pi}{2} \sum_{s=t-W+2}^t \text{sgn}(r_s) \cdot |r_s| \cdot |r_{s-1}|}{\text{RV}_W + \varepsilon}, -10, +10\right)$$

与 signed_rv 互补: 含 $|r_{s-1}|$ 项, 单 **tick** 极端值 (跳跃) 不会单独放大比率 $\rightarrow$ 比 signed_rv 更抗噪, 信号鲁棒。- **vol_burst** (Volume Burst, 成交量突发倍数) / **amt_burst** (Amount Burst, 成交金额突发倍数) (**4 维**, $W \in \{20, 50\}$):

$$\text{vol_burst}_{t,W} = \text{clip}\left(\frac{v_t}{\mu_W(v) + \varepsilon}, 0, 100\right), \quad \text{amt_burst}_{t,W} = \text{clip}\left(\frac{|\Delta \text{amt}_t|}{|\mu_W(\Delta \text{amt})| + \varepsilon}, 0, 100\right)$$

物理含义: 当前 tick 活跃度是过去 W tick 平均的几倍; > 1 = 活跃突增, < 1 = 平静期。clip(0, 100) 防极端值爆炸。

- **rv_ratio** (RV Ratio, 短/长窗实现波动率比) **3 维**:

$$\text{rv_ratio}_{W_n, W_d} = \text{clip}\left(\frac{\text{RV}_{W_n}}{\text{RV}_{W_d} + \varepsilon}, 0, 100\right), \quad (W_n, W_d) \in \{(5, 50), (20, 100), (50, 100)\}$$

短窗 / 长窗 RV 之比 $\rightarrow$ 局部活跃度变化率: 比值 $> 1 \rightarrow$ 最近 W_n tick 波动率高于长期 baseline $\rightarrow$ 可能是新信息到来 / 订单流冲击。- **jshare** (Jump Share, 跳跃份额; **Barndorff-Nielsen & Shephard 2004**, “Power and

Bipower Variation with Stochastic Volatility and Jumps , Journal of Financial Econometrics)
4 维, $W \in \{20, 30, 50, 100\}$:

$$BV_{t,W} = \frac{\pi}{2} \sum_{s=t-W+2}^t |r_s| \cdot |r_{s-1}|$$

$$jshare_{t,W} = \text{clip} \left(\frac{RV_{t,W} - BV_{t,W}}{RV_{t,W} + \varepsilon}, 0, 1 \right)$$

BNS 跳跃不变量: BV 是相邻两 tick 绝对 return 的乘积之和, **单 tick 极大值 (跳跃)** 不会同时影响相邻两项 $\rightarrow$ BV 是「连续扩散部分的二次变差」的稳健估计。因此 $RV - BV \approx$ 跳跃贡献, $jshare =$ 跳跃占总波动的比例 $\in [0, 1]$ 。

- **roll_eff_spr_ratio** (Roll Effective Spread Ratio, Roll 有效价差比; **Roll 1984, "A Simple Implicit Measure of the Effective Bid-Ask Spread in an Efficient Market"** , Journal of Finance) **3 维**, $W \in \{30, 50, 100\}$:

$$\text{roll_eff_spr_ratio}_{t,W} = \text{clip} \left(\frac{2\sqrt{\max(0, -\text{cov}_W(\Delta P_t, \Delta P_{t-1}))}}{\text{spread}_t^{(1)} + 1}, 0, 10 \right)$$

分子 = Roll (1984) 经典有效价差估计: **负自协方差** $\rightarrow$ 买卖方向交替 (bid-ask bounce) $\rightarrow$ 价格在 mid 附近反弹 $\rightarrow$ 分子即有效价差。**分母** $\text{spread}_t^{(1)} + 1$ (+1 为 magic constant, 防 $\text{spread}=0$ 时除零)。ratio $< 1 \rightarrow$ 有效价差小于报价价差 $\rightarrow$ 市场流动性良好; $W = 100$ **被 KS drop** (跨 sym Roll 估计不稳, 见 Q3)。

F4 NaN 摘要: 2 raw (volume_delta / amount_delta) 公式层无兜底, NN 路径 wz 三层; LGB 不动; 实测 NaN $\approx 0\%$ 。
 所有 27 个派生字段含 + ε 防除零 + np.where(isfinite, x, 0) + clip 三重兜底; 实测 NaN = 0%。

F5 窗口统计: 0 raw + 67 派生·gain 5.2% - OOD 主力 family

100% 派生、家族内 $|r| = 0.07$ 全场最低 (近正交)、与其他 5 族 $|r| \leq 0.07$ 。5.2% gain 是「无冗余 5.2%」, 是跨股泛化的几何基础。

- **dualz_c** (Dual-window z-score, 双窗 z-score) **37 维—决胜 OOD 的 trick**: 对 **37 个 raw 字段** (spread1-5、bid_diff1-5、ask_diff1-5、bsize1-5、asize1-5 等共 37 列) 分别做

$$\text{dualz}(c)_t = \frac{c_t - \mu_{20}(c)}{\sigma_{20}(c) + \varepsilon} - \frac{c_t - \mu_{100}(c)}{\sigma_{100}(c) + \varepsilon}$$

直觉: 当前 tick 相对短期均值偏离 **多于** 长期均值偏离的程度; **对均值水平不敏感** (两 z 相减消除全局基差)、对方差鲁棒 (除以 σ)。

- **qrank_W100_c** (Quantile Rank, 分位排名) **20 维**:

$$\text{qrank}_{W=100}(c)_t = \frac{1}{100} \sum_{s=t-99}^t \mathbf{1}[c_s \leq c_t] \in \left[\frac{1}{100}, 1\right]$$

当前值在过去 100 tick 的经验分位数。注: tick-quantized 列 (如 spread1/5/10 大多等于 1 tick, cumspread 也是) **qrank** 几乎恒 = 1 $\rightarrow$ 死特征 $\rightarrow$ 被 KS drop (drop 11 中有 4 个来自 qrank_spread)。- **mid_ewma_resid_a0.05** (Midprice EWMA Residual, 中间价 EWMA 残差) **1 维**:

$$\text{resid}_t = mp_t - \text{EWMA}_{\alpha=0.05}(mp)_t$$

$\alpha = 0.05$ 对应半衰期 $HL \approx 13 \text{ ticks} \approx 40 \text{ 秒}$ ($HL = \ln 2 / (-\ln(1 - \alpha))$, 见 §0.2)。mid 减去其低通 EWMA $\rightarrow$ **高频偏离量**: 正值 = mid 暂时高于趋势, 负值 = 暂时低于趋势。clip 到 $[-0.05, +0.05]$ 。- **adapt_mom** (Adaptive Momentum, 自适应动量) **3 维**, $W \in \{20, 50, 100\}$:

$$\text{adapt_mom}_W = \text{clip} \left(\text{sgn} \left(\sum_{s=t-W+1}^t r_s \right) \cdot \sqrt{RV_W}, -10, +10 \right)$$

方向 $\times$ 强度: 符号由窗口内累计 return 方向决定, 幅度由 $\sqrt{RV_W}$ 决定。波动大时信号幅度更强; $\sqrt{\cdot}$ 比直接用 RV 量纲压缩更均匀。- **spread_reg** (Spread Regime, 价差体制 = 鲁棒 z-score on spread) **3 维**, $W \in \{20, 50, 100\}$:

$$\text{spread_reg}_W = \text{clip} \left(\frac{\text{spread}_t^{(1)} - \text{median}_W(\text{spread}^{(1)})}{\text{IQR}_W(\text{spread}^{(1)}) + \varepsilon}, -10, +10 \right)$$

鲁棒 z-score (对常数 spread 不爆: IQR = 0 时 ≈ 0 , 而非 inf)。刻画当前 spread 相对近期中位数偏高 / 低 $\rightarrow$ 流动性 regime 变化信号。- **trade_pers** (Trade Persistence, 交易持久性) **3 维**, $W \in \{20, 50, 100\}$:

$$\text{trade_pers}_W = \text{clip}(\text{corr}_W(\text{sgn}(\Delta mp_s), \text{sgn}(\Delta mp_{s-1})), -1, +1)$$

相邻方向自相关: > 0 = 趋势 (涨继续涨、跌继续跌), < 0 = 反转 (价格在 mid 附近震荡), ≈ 0 = 随机游走。

F5 NaN 摘要: 100% 派生。dualz (37 维) 含 EPS + np.where(isfinite, x, 0); qrank (20 维) 比较运算恒 finite; mid_ewma_resid / adapt_mom / spread_reg / trade_pers 均含 EPS + isfinite 兜底 + clip。NN 路径 wz 三层或 nan_to_num(0); LGB 不动。实测所有 **F5 特征 NaN = 0%**。

F6 不对称性: 40 raw + 34 派生 = 74 维 **gain 6.3%**

F6 家族定位: 「买卖两侧不对称」家族——对买侧 (bid) 和卖侧 (ask) 分开建特征, 不假设价格方向对称。买侧行为 (bid_rate、bsize_rate) 和卖侧行为 (ask_rate、asize_rate) 往往非对称, 天然可作为方向预测信号。

- **bid_rate_k / ask_rate_k** (Bid/Ask Price Rate, 第 k 档买/卖价滑动平均变化率) (**20 raw**, $k = 1, \dots, 10$): 主办方直接提供 (来源: **Kercheval & Zhang 2015**, 赛题 PDF 定义「十档价格平均变化率」)。官方未给出精确公式, 按论文命名约定推断为:

$$\text{bid_rate}_t^{(k)} = \frac{\bar{b}_{[t-W:t]}^{(k)} - \bar{b}_{[t-2W:t-W]}^{(k)}}{|\bar{b}_{[t-2W:t-W]}^{(k)}| + \varepsilon}$$

即前 W tick 均值与再前 W tick 均值的相对变化 (具体 W 未披露, 经验 $\approx 10-20$ tick); ask_rate 同理 (卖侧)。

- **bsize_rate_k / asize_rate_k** (Bid/Ask Size Rate, 第 k 档买/卖挂量滑动平均变化率) (**20 raw**): 与 bid/ask_rate 结构相同, 对象换为 $bs_t^{(k)}$ (买侧挂量) / $as_t^{(k)}$ (卖侧挂量)。
- **GOFI** (Generalized OFI, 广义订单流不平衡; **Kercheval & Zhang 2015**) **30 派生**: $W \in \{5, 20, 60\} \times k \in \{1, \dots, 10\}$, 单 tick 增量:

$$e_t^{(k)} = \mathbf{1}[b \uparrow] \cdot bs_t - \mathbf{1}[b \downarrow] \cdot bs_{t-1} + \mathbf{1}[b =] \cdot (bs_t - bs_{t-1}) \\ + \mathbf{1}[a \uparrow] \cdot as_{t-1} - \mathbf{1}[a \downarrow] \cdot as_t - \mathbf{1}[a =] \cdot (as_t - as_{t-1})$$

(这里所有 bs 、 as 都指第 k 档; $b \uparrow$ 等表示 bid 价格相对 $t-1$ 上行 / 下行 / 不变。)

与 MLOFI 的区别: MLOFI 严格按「价格上下行」分类, **GOFI** 把「同价不变但挂量净变化」也算入流——同价 ($b =$) 情况下用 $bs_t - bs_{t-1}$ 这种「净 delta」(即挂单量的纯粹变化, 无论是撤单还是新挂)。这是 F2 $\leftrightarrow$ F6 corr 高达 0.176 的原因 (MLOFI / GOFI 同源)。

- **liq_asym_top5** (Liquidity Asymmetry top-5, 前 5 档流动性不对称) (**4 派生**, $W \in \{5, 20, 50, 100\}$):

$$\text{liq_asym}_{t,W} = \log \left(\frac{1 + \sum_{k=1}^5 \sum_{s=t-W+1}^t bs_s^{(k)}}{1 + \sum_{k=1}^5 \sum_{s=t-W+1}^t as_s^{(k)}} \right)$$

top-5 物理含义: 「前 5 档」是最优 5 档挂单量 (距成交最近的流动性)。如果买侧 5 档总量 $>$ 卖侧 5 档总量 $\rightarrow \log$ 正 $\rightarrow$ 买侧流动性更厚 $\rightarrow$ 大概率上涨 (买压较难穿透); 反之 $\log$ 负 $\rightarrow$ 卖侧更厚 $\rightarrow$ 偏向下行。 $W = 5$ 被 **KS drop** ($W = 5$ 太短, 本质单 tick 比值, 噪音太大)。

F6 NaN 摘要: 40 raw (bid/ask_rate / bsize/asize_rate) 公式层无兜底, NN 路径 wz 三层; LGB 不动。ask_rate / asize_rate 深档 ($k = 7-10$) 因涨跌停日 ask 侧无报价存在 NaN, 实测 ask_rate10 / asize_rate10 train NaN $\approx 17.13\%$, ask_rate1 $\approx 3.95\%$, bid_rate 系列 NaN = 0% (bid 侧无涨停影响)。30 个 GOFI 派生含 np.where(isfinite, x, 0) 兜底, 实测 NaN = 0%; 4 个 liq_asym 含 clip + isfinite, NaN = 0%。

三类关键预处理 (PPT p7)

1. window-z score (输入归一化) ——单贡献 +22.88 PnL

$$\text{wz}(x)_t = \frac{x_t - \mu_{100}(x_t)}{\sigma_{100}(x_t) + \varepsilon}$$

100-tick 滚动窗口内的 z-score (trailing window, 不含未来)。所有统计量在 100-tick 切片内自适应归一化, 跨股分布差异被窗口吸收 $\rightarrow$ 训练外股票也能 **zero-shot** (见 Q2 跨股泛化证据)。

2. 买卖镜像数据增强——+2.41 PnL

每条样本 ($X, y_{\text{reg}}, y_{\text{cls}}$) 复制一份镜像:

原始	镜像
X 中所有 bid_* 列	换成对应 ask_* 列 (互换)

原始	镜像
X 中所有 $b_{size_} * \text{列}$	换成对应 $a_{size_} * \text{列}$ (互换)
y_{reg}	$-y_{reg}$
y_{cls}	$2 - y_{cls}$ (涨 $\leftrightarrow$ 跌, 平保持)

训练集 $\times 2$, 强制方向对称: 买侧 = 卖侧的镜像 $\rightarrow$ 模型对价格上行 / 下行一视同仁。

3. 稳健归一化 **sign-log1p** —— LGB 受益, NN 中性

$$\text{sign_log1p}(x) = \text{sgn}(x) \cdot \log(1 + |x|)$$

仅对 `amount_delta` 这种 $10^3 \sim 10^6$ 重尾字段 (唯一未归一化字段)。**保号对数压重尾**: 保留方向符号, 量纲从百万压到 $\sim 14\text{--}18$ 范围, 对数变换抑制极端值对 LGB 分裂阈值的干扰。

Q2: 跨日 / 跨股 泛化性证据

设计层: 硬约束 + 3 个 **eval setting**

评测端 3 条硬约束 (PPT p3 红字):

1. `date` 被置 0;
2. 测试点顺序被打乱;
3. $\text{sym} \in 0\text{--}4$ 可能含训练外股票 $\rightarrow$ 必须 **sym-agnostic** (与 **sym** 无关)。

所有 370 个因子都满足: (i) 不显式用 `date / sym`; (ii) 每条样本独立可算 (不依赖跨样本状态); (iii) 不嵌入 `sym embedding / sym-conditional` 归一化。

3 个 **eval setting** (PPT p5):

Setting	划分	OOD 维度
Train-Val-Test	<code>date</code> 0-79 / 80-95 / 96-119 单一切分	日期 OOD; test zero-tune 最终评分
LOSO-date	K-fold by date ($K = 5$)	日期 OOD; stock 全 in-sample
LOSO-stock	5-fold by stock (LOSO = Leave-One-Sym-Out)	股票 OOD; 验证 sym-agnostic 假设

跨股泛化关键证据

1. **window-z** 单 **trick +22.88 PnL** (NN 路径 154 raw + L2 + window-z vs 154 raw + L2: $+0.52 \rightarrow +23.40$)。LGB 分裂阈值是绝对值的; 若 train 一只 **sym spread** $\sim 10^{-3}$ 、test OOD **sym spread** $\sim 3 \times 10^{-3}$, 训练阈值在测试上全错位。window-z 把绝对值映射到无量纲 z , 「分裂可比性」得以恢复。
2. **T7** (实验 SchemeD1: 154 raw + L2 + window-z) 加 **window-z** 后, **sym** = 2 (异常蓝筹 / ETF) **cum_pnl** 从 -0.98 翻到 $+2.24$ —全 **sym** 翻正, 证明 window-z 解决了 **sym** 间分布差异。
3. **T10** (实验 SchemeF: 全局 **z-score** 替换窗口 **z-score**) 反例: 把窗口 **z-score** 换成全局 **z-score** (基于整训练集统计量) $\rightarrow$ **LOSO** (Leave-One-Sym-Out) $h_{10} +13.40$, 反而退化。原因: 全局统计量被训练 **sym** 主导, OOD **sym** 时 $(x - \mu_{\text{global}}) / \sigma_{\text{global}}$ 不再以 0 为中心。窗口 > 全局 > **per-sym** (**per-sym** 直接违约束)。
4. **F5** 与所有其他族 $|r| < 0.07$ (近正交) —**dualz / qrank** 把「绝对水平」扔掉、留「相对位置」, 这是 **F5** 提供独立 OOD 信号的几何解释; 5.2% **gain** 是无冗余 5.2%。
5. **F1 + F3** 块间 **corr** = **0.035** —两个最重要的家族几乎正交, LGB 同时拿到两者获得「几乎无冗余」的高信息组合。
6. 公榜结果: baseline DeepLOB $-6.65 \rightarrow$ 加 SchemeC $+4.07 \rightarrow$ +window-z & 回归 $+19.23 \rightarrow$ +SPO+ DFL $+28.16 \rightarrow$ +LGB 全量重训 $+34.44 \rightarrow$ ensemble $+35.64$ 。公榜本身就是 OOD (日期 80-119 之后的 **sym** 0-4 + 可能新股票), window-z 是其中两个核心泛化 **trick** 之一。
7. 私榜 #1 ($h = 60$ 时 $+41.61$ 、 $h = 40$ 时 $+38.65$): 私榜与公榜不同日期、不同样本, 整体性能甚至更高—说明因子工程的泛化没有「踩公榜运气」。

跨日泛化关键证据

1. **L1 $\rightarrow$ L7 progressive 5-seed** (按 family 累加加入派生, 时间切分 Train 0-79 / Val 80-95 / Test 96-119):
 - L1 154 raw $\rightarrow 17.7 \pm 1.33$
 - +F1 (**wmp** 11) $\rightarrow 17.5$ (≈ 0 , **wmp** 是 raw bid / ask 的加权和, 信息冗余)
 - +F2 (**OFI** 48) $\rightarrow 22.6$ ($+5.1$)
 - +F3 (**intst** 27) $\rightarrow 25.7$ ($+3.1$)
 - +F4 (**vol** 32) $\rightarrow 24.9$ (-0.8)
 - +F5 (**win** 63) $\rightarrow 26.3$ ($+1.4$)
 - +F6 (**asym** 35) $\rightarrow 27.3$ ($+1.0$)
 每一步加入 family 都用 训练区完全没看过的 **date 96-119** 评分, 证明累加因子都不是 in-sample 过拟合。
2. **M7** 全量重训 (train + val 全量 **date** 0-119 重训, 迭代数 $\times 1.1$) 单 **trick** 给 LGB $+4.3$ 、给最终公榜 $+5.51$ 。能成立的前提是因子在跨日上稳定 (否则全量重训只会 **overfit** 验证集)。
3. **mid_ewma_resid_a0.05** 和 **dualz** 等长窗 EWMA / **z** 因子刻意选 $W = 100$ (≈ 5 min), 覆盖跨日内的「分钟级 regime shift」但不跨日。

family	n	跨股 stable	跨股 mild	跨股 strong	跨日 stable	跨日 mild	跨日 strong
F1	105	1	35	69	25	44	36
F2	50	0	3	47	50	0	0
F3	45	10	6	29	41	4	0
F4	29	1	18	10	22	7	0
F5	67	22	9	36	64	3	0
F6	74	1	11	62	67	0	7

关键观察: F5 跨日 64 / 67 stable + 跨股 22 / 67 stable, 是所有 family 里跨股 stable 占比最高、跨日几乎全 stable 的族 → 这就是「F5 是 OOD 主力 family」的硬数据证据。

Q3: KS-drop 11 features 的过程与效果

§Q3.0 KS-2sample 检验的数学定义

双样本 **Kolmogorov-Smirnov** 检验: 给定两组独立样本 $X = \{x_1, \dots, x_n\}$ (sym i 上该特征的取值) 和 $Y = \{y_1, \dots, y_m\}$ (sym j 上该特征的取值), 定义各自的经验累积分布函数 (**empirical CDF**):

$$F_n(x) = \frac{1}{n} \sum_{k=1}^n \mathbf{1}[x_k \leq x], \quad G_m(x) = \frac{1}{m} \sum_{k=1}^m \mathbf{1}[y_k \leq x]$$

KS 统计量 $D_{n,m}$ = 两个 CDF 之差的最大绝对值 (sup-norm 距离):

$$D_{n,m} = \sup_x |F_n(x) - G_m(x)| \in [0, 1]$$

物理含义: - $D = 0$ → 两组完全同分布 - $D = 1$ → 完全分离 (一组所有值大于另一组最大值) - $D > 0.5$ → 在这一点两个 CDF 至少差 50 个百分点 → 严重分布漂移

理论 p-value (基于 Kolmogorov 分布):

$$p = 2 \sum_{i=1}^{\infty} (-1)^{i-1} \exp(-2i^2 \lambda^2), \quad \lambda = \sqrt{\frac{nm}{n+m}} D_{n,m}$$

为什么本项目不用 **p-value** 而用 **D 阈值**: $N \approx 1.4M$ (每只 sym $\approx 295K$), λ 巨大, 即使 $D = 0.001$ 也得 $p \rightarrow 0$ → 所有 feature 都「统计显著」→ p-value 完全失去判别力。改用 **effect size D 阈值** 直接量化分布差异强度, 这是工程上更稳健的做法。代码注释明确说明 (validate_sym_invariance.py:4-5):

“max KS statistic across pairs. With 1.4M samples KS p-values are always tiny”

§Q3.1 失效标准

实际执行流程 (来自 T68_stage5_features/validate_sym_invariance.py:22-38):

```
for each feature column ci in 370:
    # 1. 按 sym 切分 (5 只股票 → 5 组样本)
    arr_per_sym = [X[sym == s, ci] for s in {0, 1, 2, 3, 4}]
    arr_per_sym = [a[np.isfinite(a)] for a in arr_per_sym] # 丢 NaN/Inf

    # 2. Pairwise KS: C(5, 2) = 10 对全部两两比
    stats = []
    for (i, j) in combinations(range(5), 2):
        x = subsample(arr_per_sym[i], 50_000) # 各采 50K 行加速
        y = subsample(arr_per_sym[j], 50_000)
        D_ij, p_ij = scipy.stats.ks_2samp(x, y)
        stats.append((i, j, D_ij))

    # 3. 取 10 对里"最差"的 (worst KS = 最大 D)
    worst_D = max(D for (_, _, D) in stats)

    # 4. 三档判定
    if worst_D > 0.5: flag = "FAIL" # → drop
    elif worst_D > 0.1: flag = "WARN" # → 保留但警告
    else: flag = "PASS"
```

□ **关键纠正**：之前 ANSWERS_P3_FEATURES.md 里写的「对每个 sym 单独看该特征在该 sym 上的分布 vs 全局训练分布做 KS test, $p < \alpha$ 」**两处不严格**：1. 不是「sym vs 全局」，而是 **5 只 sym pairwise 10 对两两比**，取最差 D 2. 不是「 $p < \alpha$ 」，而是「**worst pairwise $D > 0.5$** 」（ N 太大时 p-value 永远显著）

§Q3.2 11 个被 drop 的特征

#	特征名	族	worst D	stage	失效原因（数据 + 理论）
1	dualz_ask_diff1	F5	0.5011	stage1	ask 侧 1-level diff 跨 sym CDF 差约 50%（sym 间深档报价行为差异显著）
2	dualz_bid_diff5	F5	0.5029	stage1	5-level bid 价差跨 sym 漂
3	dualz_ask_diff5	F5	0.5019	stage1	同上，ask 侧 5-level
4	qrank_W100_spread1	F5	0.8564	stage2	spread1 多为 1 tick → qrank 几乎恒 1 → 跨 sym CDF 极端分离
5	qrank_W100_spread5	F5	0.8484	stage2	spread5 tick-quantized 同因
6	qrank_W100_spread10	F5	0.8374	stage2	同上
7	qrank_W100_cumspread5	F5	0.8549	stage2	累积 spread 同因
8	kyle_lam_W50	F2	0.9503	stage2	接近完全分离！Kyle λ 定义为资金流与 Δmid 的协方差除以资金流方差，跨股资金—价格弹性根本不同 → 整族 KS fail
9	kyle_lam_W100	F2	0.9758	stage2	同上，更长窗更严重
10	roll_eff_spr_ratio_W100	F100	0.5348	stage3	$W = 100$ 太长，跨 sym Roll 估计在不同活跃度股上偏差大
11	liq_asym_top5_W5	F6	0.5161	stage5	$W = 5$ 太短，单 tick top-5 比值噪声 + 跨 sym 流动性结构异

数据来源:experiments/T59_fullsym_train/sym_invariance_report.json(10 个)+ experiments/T68_stage5_features(1 个 STAGE5)。

额外洞察：Kyle λ 两档 worst D 高达 0.95–0.98（CDF 几乎完全分离）→ 这是 Kyle λ 整族被 drop 最硬的证据；qrank-on-spread 4 个 0.83–0.86 → 死特征 + tick 量化双重失败；3 个 dualz_*_diff 都贴 0.50 阈值 → 边界 fail。

§Q3.3 Design Debt

- 阈值 **0.5** 是经验值，没做 **sensitivity sweep**：试过 0.3 / 0.7 名单怎么变？没做。
- **subsample** 固定 **50K + seed=0**：换 seed 名单稳定性如何？没测。
- 没做 **Bonferroni** 多重检验修正：370 列 × 10 对 = 3700 次检验。但这其实不重要，因为最终用的是 D 阈值（effect size）而非 p-value test → Bonferroni / FWER 控制的是 p-value 的 false discovery，对 effect size 不适用。
- **WARN** 档（28 个， $0.1 < D \leq 0.5$ ）选择保留而不 **drop**：保留理由是 D 没到 0.5 → 跨 sym 漂移有限，模型 + window-z 可以兜底；drop 这些会减少模型能用的信号维度（28 个 feature 不少）。没做 **ablation** 验证这个选择——是否 drop WARN 也能保 std 不变？未知。
- 对称性 **anomaly**：dualz_bid_diff1 保留（ $D = 0.456$ WARN）但 dualz_ask_diff1 drop（ $D = 0.5011$ FAIL）——bid 侧勉强卡在 WARN 上限，ask 侧勉强越过 FAIL 下限。A 股流动性买卖侧本就不对称（涨跌停日 ask 侧深档无报价），ask 侧分布差异天然大。**这不是 design bug，是阈值 0.5 卡边界时的自然结果。**

§Q3.4 效果（5-seed 直接对比，Train-Val-Test setting, test = date 96–119）

Backbone	370-d no drop	359-d drop 11	Δ mean	Δ std
LGB L2	27.28 ± 2.34	26.58 ± 0.96	−0.70	std − 59%
NN L2 + window-z	34.77 ± 1.39	34.34 ± 0.50	−0.43	std − 64%

关键解读：drop 11 牺牲约 0.5 个 mean PnL，但 **seed-to-seed std 砍掉 60%**。

- seed std 衡量「模型对训练随机性的敏感度」。
- OOD 上 std 高的模型在公榜 / 私榜会「运气依赖」，单次提交可能高也可能低。
- drop 11 后的 359-d 模型才是 50-seed ensemble + 公榜部署的 **稳定基底**。
- 一页纸消融表 row 9 → row 10 写的「drop 11 → −1.57」是消融表链式差值（NN 路径 +F6 累加后再 drop 11），与 5-seed 直比的 −0.43 方向一致、数值不同。

Why drop 让 std 大降: 被 drop 的 11 个都是「在某些 sym 上几乎是常数 / 死特征 / 极噪声」的列。LGB 偶尔会用这种「死列」做分裂、形成 spurious 路径；不同 seed 下走的 spurious 路径不同 → seed 间分歧大。drop 后强制模型只能用「跨 sym 同分布」的列，决策面更稳。

Q4: 为什么 h=60 为主线? —horizon 选择的 5 层论证

评分规则 $\text{Score} = \max_{h \in \{5, 10, 20, 40, 60\}} \sum_i \text{pnl}_i^{(h)}$ (5 个 horizon 取最大)，看上去给了 5 个选择，实际上只有 **h=60** 在 OOD 上最终胜出。下面 5 层论证为什么。

Q4.1 评分公式 + 实测: 短 h 在 OOD 上完全失效

回顾单笔 PnL 公式:

$$\text{pnl}_i^{(h)} = (\hat{a}_i - 1) \cdot \frac{\Delta mp^{(h)}}{mp_{t+1}} - f \cdot |\hat{a}_i - 1| \cdot \frac{mp_{t+h+1} + mp_{t+1}}{mp_{t+1}}$$

其中 $f \approx 2 \times 10^{-4}$ (双边手续费 0.02%), $\Delta mp^{(h)} = mp_{t+h} - mp_t$ 。

iter_002 SchemeC 阶段一次直接对比 (同样的 LGB 3-class CE + 多 horizon 训练 + 高置信度阈值 gate):

horizon	LOSO 本地	公榜 OOD	gap (透传 Δ)
$h = 10$	+21.86	-8.64	-30.50 (灾难)
$h = 60$	+6.30	+4.07	-2.23 (可接受)

短 h 的 LOSO 看上去好得多 (**+21.86 vs +6.30**)，但在 OOD 上立刻原形毕露 (**-8.64**)。从此后所有调参 / ensemble / 决策焦点全部以 h=60 为主线。

□ 注: 以上是 iter_002 早期 LOSO 方法学对比。更严谨的 5 horizon × 5 seed 实验 (IC 分解、PnL 分解) 详见 Q4.3b / Q4.2 / Q4.8, 揭示了短 h 失效的**真实机制** (非 IC 低, 而是 $\sigma(y_h)$ 太小撑不过手续费)。

Q4.2 信号 / 成本权衡的数学

- 成本项: $f \cdot |\hat{a}_i - 1| \cdot (mp_{t+h+1} + mp_{t+1}) / mp_{t+1} \approx 2f \approx 4 \text{ bp}$, 与 **h** 几乎无关
- 信号项: 在中间价近似随机游走的假设下 $\text{std}(\Delta mp^{(h)}) \propto \sigma \cdot \sqrt{h}$; 含 alpha 时期望 $\mathbb{E}|\Delta mp^{(h)}| \propto \sigma \cdot \sqrt{h} \cdot \text{IC}$
- 信号 / 成本比 $\propto \sqrt{h}$

$\sqrt{60/5} \approx 3.46$ —**h=60** 的信噪比是 **h=5** 的 **3.5 倍**。

实测 **IC × σ vs 成本分解** (5 horizon × 5 seed LGB, test 集, 来源: h_horizon_study/REPORT.md §D):

h	IC_test	$\sigma(y_{\text{test}})$	IC × σ	单边成本	net signal/笔
5	0.372	5.33×10^{-4}	2.0 bp	2.0 bp	≈ 0 bp
10	0.320	7.62×10^{-4}	2.4 bp	2.0 bp	+0.4 bp
20	0.250	1.10×10^{-3}	2.7 bp	2.0 bp	+0.7 bp
40	0.184	1.55×10^{-3}	2.9 bp	2.0 bp	+0.9 bp
60	0.144	1.90×10^{-3}	2.7 bp	2.0 bp	+0.7 bp

这才是 **h=60** 主线的真正原因: 不是 IC 最高 (实测反过来: IC 随 h 单调递减), 而是 **IC × σ** 在 h=60 撑得过 4 bp (round-trip) 成本, h=5 时刚好持平。

Q4.3 微结构噪声 (bid-ask bounce) —修正版

高频中间价存在 **bid-ask bounce noise**: 成交在 best bid ($b^{(1)}$) 和 best ask ($a^{(1)}$) 之间来回切换, 单 tick Δmid 有 $\pm \text{tick}$ 的虚假波动, 不反映真实方向。

实测数字 (全局 1-lag 自相关, 来源: h_horizon_study/REPORT.md §B):

- 全局 $\rho = -0.150$ (负值 = bounce 信号)
- sym3 $\rho = -0.23$ (最严重), sym2 $\rho = -0.05$ (最轻)

□ 反直觉发现 (旧说法已被实测推翻): 原先答辩小抄 Q4.3 声称「短 h 模型 in-sample 拟合 bounce → OOD 失效 → IC 低」——实测正好相反:

- 短 h IC 反而更高: $\text{IC}_{\text{test}}(h=5) = 0.372 \gg \text{IC}_{\text{test}}(h=60) = 0.144$
- 短 h train-test gap 更小: $h=5 \text{ gap} = 0.086$ (最稳), $h=60 \text{ gap} = 0.428$ (严重 overfit)
- 短 h 模型预测力更强, bounce 不是「让短 h 不可学」, 而是让 $\sigma(y_h)$ 比 $\sqrt{h}$ 基准略小 (负自相关压缩了短 h 的方差), 进一步收窄信号空间。

Bounce 的实际作用: 负自相关 (bounce share $\approx 22\%$) 部分抵消 Δmid 方差, 使 $\sigma(y_5) \approx 5.3 \times 10^{-4}$ 略低于纯 $\sqrt{h}$ 预测, 让 h=5 信号更难越过手续费门槛——但模型对短 h 的预测力并未因 bounce 而失效。

Q4.3b IC by Horizon 完整实测 (5 horizon × 5 seed)

来源: h_horizon_study/REPORT.md §C, 5 horizon × 5 seed LGB L2, 359-d schemeP, train 0-79 / val 80-95 / test 96-119

h	IC(train)	IC(test)	train-test gap
5	0.458 ± 0.020	0.372 ± 0.003	0.086 (最稳)
10	0.447 ± 0.034	0.320 ± 0.003	0.126
20	0.460 ± 0.056	0.250 ± 0.003	0.210
40	0.516 ± 0.076	0.184 ± 0.004	0.332
60	0.572 ± 0.080	0.144 ± 0.006	0.428 (严重 overfit)

关键观察: 1. IC(test) 随 h 单调递减 (短 h 模型逐 tick 预测力更强) 2. h=60 in-sample IC = 0.572 但 OOD 暴跌到 0.144, train-test gap 最大——h=60 自身也严重 overfit, 仅靠 $\sigma(y_{60})$ 足够大才让净信号仍为正 3. 短 h 不是 IC 低的问题, 是 $\sigma(y_h) \propto \sqrt{h}$ 决定的成本可行性问题

Q4.4 LOB 派生因子的时间尺度匹配

我们的 feature 是 $W \in \{5, 20, 50, 100\}$ ticks 的窗口统计 (dualz / rv_W / cancel_imb_W 等), 最长记忆 $W = 100 \approx 5 \text{ min}$ 。

- $h = 5$ (15 秒): 远短于 $W = 100 \rightarrow$ 「用 5 分钟特征预测 15 秒事件」 $\rightarrow$ 特征-标的尺度严重失配
- $h = 60$ (180 秒): $\approx W = 100 \times 60\% \rightarrow$ 特征信息正好积累足够, 又没过期——信号-标的尺度的 sweet spot
- $h = 120$ (如果有): 远长于 $W = 100 \rightarrow$ 特征对未来 6 分钟的预测力衰减

Q4.5 OOD 透传率: 长 h 模型对分布漂移更鲁棒

节点	LOSO 本地 h=60	公榜 h=60	透传率
iter_002 SchemeC	+6.30	+4.07	65%
iter_013 回归突破	+36.23	+19.23	53%
iter_015 SPO+ DFL	+40.09	+28.16	71%
iter_019 M7 LGB	+41.49	+34.44	83%

h=60 的本地 $\rightarrow$ 公榜透传率随训练成熟稳定在 50-80%, 且随着模型 / 集成提升单调改善。而短 h 透传率为负或近零 (iter_002 h=10 直接 -8.64)。

Q4.6 一句话答辩答案

「**h=60 不是因为 IC 最高 (实测反过来: $h=5 \text{ IC}=0.37 > h=60 \text{ IC}=0.14$), 是因为 $\sigma(y_h) \propto \sqrt{h}$, 短 h 的目标变量幅度太小, $\text{IC} \times \sigma \approx 2 \text{ bp}$ 刚好等于单边手续费, **net PnL ≈ 0** ; $h=60$ 的 σ 是 $h=5$ 的 $3.7\times$ (实测 1.9×10^{-3} vs 5.3×10^{-4}), 即使 IC 低, $\text{IC} \times \sigma \approx 2.7 \text{ bp} \gg$ 成本, **net PnL $\approx +0.7 \text{ bp}$** 。这不是预测能力问题, 是信号尺度问题。」**

Q4.7 h<60 实战: $\sqrt{h/60}$ 阈值缩放实测失败, h<60 必须单独训练

□ 旧说法 (已被实测推翻): 原答辩小抄 Q4.7 称「按 $\sqrt{h/60}$ 缩放阈值 $\rightarrow$ 私榜 h=40 +38.65 #1, 说明 h=60 模型有跨 horizon 迁移力」。实测发现:

h	scale $\sqrt{h/60}$	h=60 模型缩放 PnL	专训模型 PnL	Δ
5	0.289	-32.2 (破产!)	+18.6	+50.8
10	0.408	-14.3	+25.5	+39.8
20	0.577	+4.4	+29.7	+25.2
40	0.816	+19.5	+30.1	+10.6
60	1.000	+22.9	+22.9	0

数据来源: h_horizon_study/REPORT.md §F

真相: 用 h=60 模型 + $\sqrt{h/60}$ 阈值缩放推到 $h < 20$ 完全破产 ($h=5 \text{ PnL} = -32!$), 与专训该 h 差 +51。所以实战中 **$h < 60$ 必须单独训练, 不能简单 $\sqrt{h/60}$ 阈值缩放。**

私榜 h=40 +38.65 (#1) 实际是因为我们对 h=40 做过单独阈值调优 (非简单 $\sqrt{\cdot}$ 缩放)。

Q4.8 实测 PnL 对比: h=40 in-sample 最优, h=60 仍是 OOD 主线

DE-优化阈值后 test 集 PnL (5 seed 平均):

h	θ_{up}	θ_{dn}	n_trades	test PnL	per-trade
5	0.00033	0.00034	92,500	+18.6	$+2.01 \times 10^{-4}$
10	0.00038	0.00032	130,691	+25.5	$+1.95 \times 10^{-4}$
20	0.00036	0.00031	178,081	+29.7	$+1.67 \times 10^{-4}$
40	0.00046	0.00029	193,119	+30.1	$+1.56 \times 10^{-4}$
60	0.00063	0.00030	177,480	+22.9	$+1.29 \times 10^{-4}$

数据来源: h_horizon_study/REPORT.md §D

In-sample 最优是 h=40 (+30.1), 不是 h=60 (+22.9)——解释了为何私榜 h=40 +38.65 (#1) 与 h=60 +41.61 (#1) 几乎打平。但 h=60 OOD 透传更稳 (私榜 #1), 实战仍主押 h=60, h=40 兜底。

Q4 答辩 talking point flow

答辩建议流程（展示顺序 → 对应图/表）：

1. 「我们测试了 5 个时间尺度，发现一个反直觉结果」—展示 fig_C_IC_by_horizon.pdf
2. 「短 h 模型 IC 反而更高（h=5 IC=0.37 vs h=60 IC=0.14），train-test gap 更小，不是 IC 低的问题」
3. 「真正原因」—展示 Q4.2 新表（IC $\times \sigma$ vs cost）
4. 「 $\sigma(y_h) \propto \sqrt{h}$ （实测 $h^{0.5007}$ ），短 h σ 太小，net signal ≈ 0 」
5. 「h=40 in-sample 最优（+30.1），h=60 OOD 最稳（公榜 +35.64 / 私榜 +41.61 #1）」
6. 「 $\sqrt{h/60}$ 阈值缩放对 h < 20 破产，h < 60 必须单独训练」

老师可能追问的 7 个刁钻问题（含答案）

Q1：为什么 F1 importance 40% 但 progressive 增益 ≈ 0 ?

F1 里 94 / 105 维是 raw bid / ask / size / OHLC，已在 L1 baseline。F1 派生只剩 11 个 wmp_*, wmp 是 raw bid / ask 加权和、信息高度冗余。importance 反映的是「模型用了谁」，被 raw 价格 baseline 主导；progressive 反映的是「相对 baseline 新增了什么」，wmp 没新增信息。

Q2：F2 importance 仅 5.5% 但 progressive 加入 +5.08 是最大跳变，为啥？

F2 内部 $|r| = 0.33$ 全场最高（50 个 MLOFI 因子高度相关）。LGB 的 gain 在高相关族内被分摊到很多 feature 上，单看 share 被稀释；但作为一个整体，OFI 提供了 baseline 完全没有的「订单流方向 $\times$ 时间尺度」维度，相对 baseline 跳变最大。

Q3：为什么 ma_intst（市价卖单强度）是单因子 gain 第一？它和 OFI 不重复吗？

ma_intst = market-ask intst = 已脱敏的市价卖单总量 / 次数，直接来自主办方，不需要从价格反推 OFI 那种「逆向工程」。OFI 是从 (b, a, bs, as) 的变化间接推订单流，会有「挂单跳价」的歧义；ma_intst 没歧义。LGB 优先用最低歧义的信号当根分裂，所以 gain 最高。

Q4：为什么 5 个 OFI / Kyle 都用 $W \in \{5, 20, 60\}$ 或 $\{50, 100\}$ ，没做窗口 sweep？

这是 R34 调研阶段的固定选择，没正式 sweep (design debt)。理由：(20, 50, 100) ticks $\approx$ (1, 2.5, 5) min 是 HFT (High-Frequency Trading, 高频交易) 文献的常用尺度；窗口 sweep 一次要重算 1.47M 行 feature cache，成本高，没做。Roll $W = 30$ 、jshare $W = 30$ 等「独有窗口」是各 stage 提议时的遗留，没归一化掉。

Q5：Kyle λ 整族 KS drop 了，为什么不直接整族删除算了？

我们就是这么做的 ($W = 50$ 和 $W = 100$ 两个都 drop)。但 family report 里 F2 50 维仍包含 Kyle λ —这是 dimension 账 (370 维分组)，不是「模型用了多少」。喂模型时是 359 维 (drop 11)。Kyle λ 的位置由 KyleInv 顶上了 (KyleInv 通过 $\sqrt{\cdot}$ 重整 $\Delta amt \rightarrow$ 跨 sym 量纲更稳)。

Q6：window-z 用 100-tick (≈ 5 min) 会不会泄露未来？

不会。window-z 是 **trailing window**：对当前 tick t ，用的统计量是 $[t - 99, t]$ 全部历史 tick；不含 $t + 1$ 及之后。两个关键代码位置：

- cfg["wz"]: mu = np.nanmean(tr["X"], axis=0) 在 train 上算全局 mu / sd 套到 val / test，保证三集同口径，避免 train / val / test 分布偏移。
- dualz 算法里 seg20 / seg100 都从 X3d[:, -W:, :] 取，永远是过去 W tick。

Q7：KS test drop 11 是不是会 overfit 训练集的 sym 0-4？OOD 新 sym 上还有效吗？

风险确实存在 (KS 用训练 sym 算分布)。我们的兜底是：(i) drop 的列要么 in-sample 就近乎死特征 (qrank on quantized spread)、要么 W 太短 / 长极噪声 (liq_asym $W = 5$ 、roll $W = 100$)，这些「病态特征」在任何 sym 上都不该贡献信号；(ii) 公榜 / 私榜两套不同 OOD test 上 359-d 模型都拿到 #1，证明 drop 列表对训练外 sym 也鲁棒。

一句话总结

6 大家族 (370 维) + 3 类 sym-agnostic 预处理 (window-z / 镜像 / sign-log1p) + KS drop 11 (359 维稳定基底) + 50 $\times$ 50 异质 ensemble，把跨股 + 跨日 OOD 风险层层吸收，最终公榜 +35.64 (baseline -6.65) / 私榜 #1 (+41.61)。